Projekt Inżynierski - Harmonogram Pracy

Laura Nowak, Szymon Smoła, Kacper Szmigielski

2026-10-21

1. Spis literatury wraz z opisem zawartości i przydatności w projekcie

Spis pisany był z redakcją sztucznej inteligencji (Gemini 4 Argon) oraz na bieżąco kontrolowany z treścią poniższych, czytanych przez nas artykułów.

[1] Hyndman, R. J., & Athanasopoulos, G. (2018 / 2021). *Forecasting: principles and practice*, 2nd ed. (rozdz. 10) / 3rd ed. (rozdz. 11). OTexts. https://otexts.com/fpp2/ oraz https://otexts.com/fpp3/

- **Zawartość opracowania:** Autorzy wprowadzają ścisłe rozróżnienie między szeregami hierarchicznymi a szeregami grupowanymi. W pracy omówiono problem niespójności niezależnych prognoz bazowych oraz klasyczne metody uzgadniania prognoz (***BU***, ***TD*** z proporcjami historycznymi i prognozowanymi oraz ***MO***). Ponadto przedstawiono miarę błędu **MASE** (*Mean Absolute Scaled Error*), umożliwiającą porównywanie dokładności prognoz szeregów o różnych skalach. W podręczniku skrótowo omówiono również nowsze podejścia oparte na optymalnym uzgadnianiu prognoz, w tym metodę *MinT*.
- **Przydatność i wykorzystanie w projekcie:**
  1. Zastosujemy modele **ETS** oraz **ARIMA** jako główne statystyczne metody generowania prognoz bazowych. Do automatycznego doboru parametrów modeli ARIMA wykorzystamy m.in. funkcję `forecast::auto.arima()` dostępną w środowisku R.
     Modele naiwne (*Naive / Seasonal Naive*) posłużą jako proste punkty odniesienia.
  2. Wykorzystamy miarę **MASE** (obok MAE, RMSE i MAPE) do oceny i porównania dokładności prognoz **na wszystkich poziomach hierarchii – od poziomu najwyższego, przez poziomy pośrednie, aż do poziomu najniższego**.
  3. Wykorzystamy przedstawione w podręczniku metody ***BU***, ***TD*** oraz ***MO*** jako podstawowe podejścia do uzgadniania prognoz. Uwzględnimy również metody oparte na **optymalnym** uzgadnianiu prognoz opartych na **MASE**, takie jak **OLS**, **WLS** i **MinT**, w celu porównania ich skuteczności z podejściami klasycznymi.

[2] Hyndman, R. J., Ahmed, R. A., Athanasopoulos, G., & Shang, H. L. (2011). *Optimal combination forecasts for hierarchical time series.* Computational Statistics and Data Analysis, 55(9), 2579-2589. https://robjhyndman.com/publications/hierarchical/

- **Zawartość opracowania:** Autorzy proponują odejście od metod jednopoziomowych na rzecz niezależnego wyznaczenia prognoz bazowych na wszystkich poziomach, a następnie ich uzgodnienia za pomocą regresji liniowej. W pracy udowodniono matematycznie, że metody *Bottom-Up* oraz *OLS* dają prognozy nieobciążone, podczas gdy każde podejście *Top-Down* zawsze wprowadza obciążenie statystyczne.
- **Przydatność i wykorzystanie w projekcie:** Zestawimy klasyczną metodę **BU** (oraz ***TD*** i **MU** dla zbioru ściśle hierarchicznego) z podejściem regresyjnym **Optimal-OLS** oraz ze standardowym podejściem bazowym. Pozwoli nam to empirycznie zweryfikować tezę autorów o nieobciążoności i przewadze metod łączących informacje ze wszystkich poziomów agregacji.

[3] Wickramasuriya, S. L., Athanasopoulos, G., & Hyndman, R. J. (2019). *Optimal forecast reconciliation for hierarchical and grouped time series through trace minimization.* Journal of the American Statistical Association (JASA), 114(526), 804-819. https://robjhyndman.com/publications/mint/

- **Zawartość opracowania:** Bezpośrednie rozwinięcie i korekta artykułu z 2011 roku. Autorzy wprowadzają metodę **Optimal-MinT**, która minimalizuje ślad macierzy kowariancji rzeczywistych błędów prognoz uzgodnionych. Praca przedstawia praktyczne sposoby estymacji macierzy kowariancji błędów jednokrokowych, w tym ważoną metodę najmniejszych kwadratów **Optimal-WLS** oraz estymator ze ściąganiem **Optimal-MinT-Shrink**, który pozwala na odwrócenie macierzy kowariancji nawet przy bardzo dużej liczbie szeregów. Wykazano, że na najniższych poziomach hierarchii silny szum uniemożliwia modelom ARIMA i ETS wykrycie sezonowości w ponad połowie szeregów, a metoda MinT potrafi przekazać sygnał sezonowy z wyższych poziomów w dół.
- **Przydatność i wykorzystanie w projekcie:**
  1. Artykuł stanowi bezpośrednie uzasadnienie teoretyczne dla wybranej przez nasz zespół metody **Optimal-MinT** oraz metod **Optimal-WLS**, które obok metod **BU**, **TD** oraz **MO** będą głównymi zaawansowanymi metodami uzgadniania w naszych badaniach.
  2. Zainspirowani wynikami autorów, zbadamy skuteczność metod w przekrojach różnych horyzontów prognozy (h) - sprawdzimy, czy *MinT* faktycznie poprawia jakość modeli **ARIMA** i **ETS** na najniższym poziomie hierarchii.

[4] Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). *M5 accuracy competition: Results, findings, and conclusions.* International Journal of Forecasting, 38(4), 1346-1364. https://doi.org/10.1016/j.ijforecast.2021.11.013

- **Zawartość opracowania:** Podsumowanie wyników konkursu prognostycznego M5 opartego na hierarchiczno-grupowanych danych o dziennej sprzedaży produktów w sieci Walmart (12 poziomów agregacji, 42 840 szeregów). Autorzy porównali klasyczne modele statystyczne (ARIMA, ETS) z algorytmami uczenia maszynowego (głównie *LightGBM* oraz sieciami neuronowymi). Najlepsze rozwiązania ML uzyskały wynik średnio o 22,4% lepszy od najlepszych benchmarków statystycznych, przy czym przewaga ta zależała od poziomu agregacji (wynosiła ok. 53% na najwyższym poziomie i ok. 3% na najniższym, silnie zaszumionym poziomie z przerywanym popytem). Podkreślono kluczową rolę globalnego uczenia modeli (*cross-learning*), inżynierii cech (opóźnienia, kroczące średnie) oraz łączenia prognoz z różnych poziomów agregacji.
- **Przydatność i wykorzystanie w projekcie:**
  1. Stanowi podstawę do ewentualnego włączenia w naszym projekcie modelu uczenia maszynowego (np. **LightGBM** / **XGBoost**) jako alternatywnego generatora prognoz bazowych i skonfrontowania go z klasycznymi modelami **ARIMA** oraz **ETS** oraz modelami naiwnymi (*Naive / Seasonal Naive*).
  2. Zgodnie z wnioskami z artykułu, będziemy mogli sprawdzić, czy przewaga modelu ML nad ARIMA/ETS oraz modelami naiwnymi (*Naive / Seasonal Naive*) w naszych zbiorach danych również zmienia się w zależności od poziomu agregacji oraz jak prognozy wygenerowane przez ML zachowują się po nałożeniu uzgadniania **MinT** i **Bottom-Up**.

[5] Spiliotis i inni (2021). *Hierarchical forecast reconciliation with machine learning.* Applied Soft Computing.

Źródło wskazane przez prowadzącego: https://www.sciencedirect.com/science/article/pii/S1568494621006773.

- **Zakres i planowane wykorzystanie:** Praca dotycząca zastosowania uczenia maszynowego do uzgadniania prognoz hierarchicznych. Posłuży do zaprojektowania ewentualnego rozszerzenia planu maksimum oraz rozróżnienia dwóch zastosowań ML: generowania prognoz bazowych i samego uzgadniania prognoz. Wybór konkretnego rozwiązania nastąpi po analizie publikacji oraz dostępnych implementacji.

[6] **Aikawa i inni (2026).** ***Hierarchical Time Series Forecasting with Robust Reconciliation.*** **Transactions on Machine Learning Research.**

Źródło wskazane przez prowadzącego: https://openreview.net/pdf?id=XHPLjF52gY.

Kod autorów: https://github.com/isct-nakatalab/hierarchical-tsf-robust-reconciliation.

- **Zakres i planowane wykorzystanie:** Praca wskazana jako podstawa rozszerzenia o odporną estymację macierzy kowariancji w uzgadnianiu prognoz. W planie maksimum rozważymy porównanie odpornego wariantu z podstawowym Optimal-MinT, szczególnie w obecności obserwacji odstających. Dobór ustawień i implementacji będzie poprzedzony analizą publikacji i kodu autorów.

Shrinkage i odporna estymacja kowariancji będą traktowane jako odrębne zagadnienia: stabilizacja estymacji macierzy nie oznacza automatycznie odporności na obserwacje odstające.

2. Wstępnie planowane narzędzia do użycia w projekcie

- **R** wykorzystywany do eksploracyjnej analizy danych, budowania modeli, ewaluacji i budowania raportu

Brane pod uwagę:

- **Python** jako wygodne zastępstwo dla języka **R**
- Przetwarzanie chmurowe: zastosowanie narzędzi **AWS** lub **Azure** do badania i walidacji modeli, aby móc przeprowadzić cięższe obliczenia
- **PowerPoint/Beamer** - do tworzenie prezentacji

3. Harmonogram pracy

- Wszystkie terminy dotyczą 2026 roku.

19.10 — wstępny przegląd literatury i harmonogram

- Przygotowanie wstępnego przeglądu literatury.
- Określenie ogólnego celu projektu i wstępnej listy metod.
- Opracowanie pierwszej wersji harmonogramu.

Rezultat: wstępny dokument planu pracy, stanowiący podstawę dalszych uzgodnień.

29.10 — uporządkowanie podstaw teoretycznych i zakresu badań

- Uzupełnienie literatury o pozycje [5–6] i uwzględnienie uwag prowadzącego.
- Przypomnienie informacji o modelach ETS oraz ARIMA, jak i o prognozach Naive oraz Seasonal Naive.
- Wstępne zrozumienie metod łączenia prognoz hierarchicznych - BASE, BU, TD, MO, Optimal-OLS, Optimal-WLS i Optimal-MinT.
- Zaznajomienie się z rolą estymacji macierzy kowariancji.
- Ujednolicenie oznaczeń oraz doprecyzowanie celów i pytań badawczych.
- Wstępne rozpoznanie dostępnych implementacji i ograniczeń ich użycia.

Rezultat: Lepsze przygotowanie merytoryczne i poszerzenie wiedzy pomocnej w naszym projekcie. Teoretyczna lista badanych metod oraz narzędzi do sprawdzenia na danych.

02.11 — analiza kandydatów na dane i pilotaż prognozowania

- Ocena długości szeregów, częstotliwości danych, braków obserwacji, liczby szeregów i struktury agregacji.
- Wstępna analiza trendu, sezonowości, autokorelacji, zmienności wariancji i obserwacji odstających.
- Sprawdzenie, czy struktura umożliwia porównanie skuteczności zaplanowanych metod prognozowania hierarchicznego.

– Pilotażowe wyznaczenie prognoz ETS i ARIMA oraz naiwnych punktów odniesienia na chronologicznym podziale danych.
– Ocena trudności prognozowania, i działania wybranych narzędzi.
– Wybór zbioru do planu minimum oraz zdefiniowanie jego hierarchii.

Pilotaż służy ocenie przydatności danych i wykonalności projektu, a nie wyborowi zbioru wyłącznie na podstawie niskich błędów.

Rezultat: uzasadnienie wyboru zbioru, analiza eksploracyjna, tabela wyników pilotażu i wybór narzędzi.

09.11 — projekt eksperymentów i procedury oceny

– Ustalenie horyzontów prognozy odpowiednich do częstotliwości i długości danych.
– Zaplanowanie chronologicznego podziału na część rozwojową i końcową część testową.
– Zdefiniowanie rolling-origin z rozszerzającym się oknem treningowym: początkowej długości okna, kroku przesuwania i liczby punktów początkowych prognoz.
– Przyjęcie obowiązkowych metryk MAE, RMSE, MASE i RMSSE oraz zasad ich agregowania na wszystkich poziomach hierarchii.
– Określenie zasad obsługi braków danych, transformacji, obserwacji odstających oraz zerowych mianowników metryk skalowanych.
– Wybór procedury oceny istotności statystycznej dla wcześniej określonych porównań metod i modeli.
– Zaprojektowanie formatu konfiguracji, zapisu wyników i prezentacji rezultatów.
– Ustalenie osób odpowiedzialnych za główne obszary projektu.

Rezultat: zamknięta specyfikacja eksperymentów i procedury oceny, umożliwiająca rozpoczęcie implementacji.

19.11 — implementacja procedury eksperymentalnej i pierwsze analizy

– Integracja gotowych implementacji modeli i metod uzgadniania.
– Implementacja parametryzowanej procedury obejmującej przygotowanie danych, budowę hierarchii, podziały czasowe, opcjonalne transformacje, prognozy bazowe i naiwne, uzgadnianie, metryki, pomiar czasu oraz zapis wyników.
– Sprawdzenie zgodności dat, kolejności szeregów i struktury agregacji.
– Kontrola braku wykorzystania przyszłych obserwacji przy estymacji parametrów, proporcji TD i macierzy kowariancji.
– Sprawdzenie, czy prognozy uzgodnione sumują się zgodnie z hierarchią.
– Wykonanie pierwszego kompletnego eksperymentu na części rozwojowej danych.
– Aktualizacja części metodologicznej raportu.

Rezultat: działająca i odtwarzalna procedura oraz pierwsze porównywalne wyniki.

23.11 — prezentacja wstępnych wyników i wybór rozszerzenia

– Przedstawienie celu projektu, pytań badawczych, danych i struktury hierarchii.
– Omówienie walidacji i metryk.
– Prezentacja pierwszych wyników według strategii, modeli, poziomów hierarchii i horyzontów.
– Ocena realizacji planu minimum i ewentualnych występujących problemów.
– Wybór co najwyżej jednego głównego rozszerzenia do planu maksimum, jeżeli postęp prac i dostępny czas na to pozwalają.

Rezultat: prezentacja wstępna i ostateczna lista eksperymentów do wykonania do 03.12.

03.12 — zakończenie eksperymentów i analiza wyników

- Wykonanie pełnego zestawu eksperymentów planu minimum na końcowej części testowej według wcześniej ustalonych reguł.
- Porównanie BASE, BU, TD, MO, Optimal-OLS, Optimal-WLS i Optimal-MinT.
- Analiza wpływu modelu bazowego, horyzontu prognozy i poziomu hierarchii na jakość prognóz.
- Ocena istotności statystycznej wcześniej zaplanowanych porównań oraz wielkości obserwowanych różnic.
- Realizacja wybranego rozszerzenia, jeśli ukończono plan minimum.
- Sformułowanie odpowiedzi na pytania badawcze i opis ograniczeń.
- Uzupełnienie raportu o końcowe tabele, wykresy i interpretację.

Rezultat: komplet wyników i zasadniczo gotowy raport do korekty.

07.12 — raport końcowy i prezentacja

- Sprawdzenie spójności terminologii, oznaczeń, tabel i wykresów.
- Uporządkowanie kodu, konfiguracji i instrukcji odtworzenia eksperymentów.
- Przygotowanie prezentacji końcowej z odpowiedziami na pytania badawcze.
- Omówienie ograniczeń i możliwości dalszych badań.
- Podsumowanie wkładu członków zespołu.

Rezultat: raport końcowy, prezentacja i uporządkowany kod projektu.

Podział pracy

Najpóźniej do 09.11 ustalimy osoby odpowiedzialne za: przygotowanie danych i hierarchii, procedurę eksperymentalną oraz analizę wyników i raport. Podział będzie aktualizowany stosownie do potrzeb, a kluczowe decyzje metodologiczne będą podejmowane wspólnie. Raport końcowy będzie zawierał rzeczywisty zakres wkładu każdej osoby.

4. Pytania badawcze

1. **Wpływ modelu bazowego:** Jak wybór modelu bazowego (np. ETS, ARIMA, modele uczenia maszynowego) wpływa na ostateczną dokładność prognoz w hierarchicznych szeregach czasowych?
2. **Skuteczność metod uzgadniania:** Która z analizowanych metod uzgadniania prognoz (BU, TD, MO, OLS, MinT) charakteryzuje się najwyższą skutecznością predykcyjną i czy różnice w dokładności między tymi metodami są statystycznie istotne?
3. **Złożoność obliczeniowa :** Jak kształtuje się relacja pomiędzy dokładnością prognoz a czasem działania poszczególnych algorytmów uzgadniania i czy czas obliczeń może stanowić decydujące kryterium wyboru metody przy zbliżonej skuteczności predykcyjnej?
4. **Wpływ horyzontu czasowego:** W jakim stopniu długość horyzontu prognozy wpływa na skuteczność predykcji w zależności od wybranej metody uzgadniania i modelu bazowego?
5. **Uogólnienie wyników:** W jakim stopniu wnioski dotyczące wyboru optymalnej metody uzgadniania, uzyskane dla analizowanych zbiorów danych, można uogólnić na nowe zbiory i czy istnieją podstawy do sformułowania uniwersalnych rekomendacji w tym zakresie?

Pytania dodatkowe (tzw. plan maksimum):

6. **Wpływ struktury hierarchii:** Czy i w jakim stopniu struktura analizowanej hierarchii – w szczególności jej głębokość oraz stopień zbalansowania – determinuje skuteczność poszczególnych metod uzgadniania prognoz?

5. Plan minimum oraz maximum

W ramach planu minimum zakładamy przeprowadzenie pełnej analizy jednego wybranego zbioru danych o strukturze hierarchicznej. Na początku wykonamy wstępną analizę szeregów czasowych, uwzględniając m.in. trend, sezonowość, autokorelację, zmienność wariancji oraz obserwacje odstające.

Następnie przygotujemy prognozy bazowe z wykorzystaniem modeli Naive, Seasonal Naive, ETS i ARIMA oraz zastosujemy wybrane metody uzgadniania prognoz: Bottom-Up, Top-Down, OLS, WLS i MinT. Otrzymane wyniki porównamy z prognozowaniem niezależnym, które nie uwzględnia struktury hierarchicznej.

Ocenę przeprowadzimy dla różnych horyzontów prognozy, korzystając z walidacji Rolling-Origin z rozszerzającym się oknem treningowym. Do porównania metod wykorzystamy przede wszystkim MASE i RMSSE. Wyniki przeanalizujemy osobno dla poszczególnych poziomów hierarchii, aby sprawdzić, kiedy uwzględnienie jej struktury rzeczywiście poprawia dokładność prognoz.

Jeżeli uda nam się zrealizować wszystkie założenia planu minimum i pozostanie wystarczająco dużo czasu, chcielibyśmy rozszerzyć projekt o dodatkowe eksperymenty.

Przede wszystkim rozważamy wykorzystanie modeli uczenia maszynowego oraz porównanie ich skuteczności z klasycznymi modelami statystycznymi. Chcielibyśmy również sprawdzić, jak prognozy uzyskane za pomocą tych modeli zachowują się po zastosowaniu metod uzgadniania hierarchicznego.

Dodatkowo, w zależności od uzyskanych wyników, moglibyśmy przeprowadzić analizę wrażliwości metod na obserwacje odstające i zmiany strukturalne oraz bardziej szczegółowo zbadać statystyczną istotność różnic w dokładności prognoz.