Prognozowanie Hierarchicznych Szeregów Czasowych

oho

2026-11-11

Spis treści

1 Merytoryczny opis metod, modeli i miar wykorzystywanych w projekcie. 1
1.1 Modele prognozowania 1
1.2 Metody prognozowania hierarchicznego 2
1.3 Miary dokładności prognoz 2

1 Merytoryczny opis metod, modeli i miar wykorzystywanych w projekcie.

1.1 Modele prognozowania

- **Modele naiwne (Naive i Seasonal Naive):** Pełnią funkcję modeli referencyjnych (benchmarków). Klasyczny model naiwny zakłada, że przyszła wartość szeregu jest równa jego ostatniej zaobserwowanej wartości ($y_t = y_{t-1}$). Model sezonowy przyjmuje natomiast, że prognoza jest równa ostatniej zaobserwowanej wartości z analogicznego okresu w poprzednim cyklu sezonowym ($y_t = y_{t-m}$, gdzie m to długość cyklu). Modele te są kluczowe do oceny, czy bardziej zaawansowane algorytmy rzeczywiście wnoszą wartość dodaną.
- **Model ETS (Error, Trend, Seasonal):** Klasa modeli oparta na metodach wygładzania wykładniczego w postaci przestrzeni stanów. Pozwala na elastyczne modelowanie struktury szeregu poprzez wygładzanie błędu, trendu oraz wahań sezonowych, uwzględniając ich addytywny lub multiplikatywny charakter.
- **Model ARIMA (Autoregressive Integrated Moving Average):** Jeden z najpopularniejszych modeli statystycznych do analizy szeregów czasowych, łączący procesy autoregresyjne i średniej ruchomej na szeregach zróżnicowanych w celu uzyskania stacjonarności. W projekcie wykorzystamy algorytm `auto.arima()`, który automatycznie przeszukuje przestrzeń hiperparametrów (p, d, q, P, D, Q) i optymalizuje model w oparciu o kryteria informacyjne (np. AIC, BIC).

1.2 Metody prognozowania hierarchicznego

Z uwagi na hierarchiczną strukturę danych, same prognozy bazowe – czyli wygenerowane niezależnie dla każdego poziomu i węzła w hierarchii – nie są spójne. Oznacza to, że suma prognoz z poziomów niższych z reguły nie zgadza się z prognozą poziomu wyższego. W celu uzgodnienia prognoz wykorzystuje się następujące metody:

- **Opcja podstawowa / Prognozy bazowe (BASE):** Podejście "naiwne" dla struktur hierarchicznych, w którym ignoruje się zależności agregacyjne, zachowując pierwotne, niezależne predykcje z modeli ETS, ARIMA itp. Służy zazwyczaj jako punkt odniesienia.
- **Bottom-Up:** Metoda polegająca na generowaniu prognoz wyłącznie dla najniższego poziomu hierarchii, a następnie agregowaniu ich w górę za pomocą prostego sumowania. Gwarantuje spójność i brak utraty informacji na poziomie szczegółowym, jednak może kumulować błędy oraz ignorować makrotrendy widoczne na wyższych szczeblach.
- **Top-Down:** Podejście odwrotne – prognoza generowana jest tylko dla głównego, najwyższego agregatu, a następnie rozbijana na niższe szczeble przy pomocy proporcji historycznych lub estymowanych prawdopodobieństw. Dobrze radzi sobie z wysoce zaszumionymi danymi na dole hierarchii.
- **Middle-Out:** Metoda hybrydowa, w której wybierany jest poziom pośredni hierarchii. Dla tego poziomu generuje się prognozy bezpośrednie, po czym agreguje się je w górę (Bottom-Up) i dezagreguje w dół (Top-Down).
- **Metody optymalne - OLS, WLS, MinT:** Nowoczesne metody macierzowe korygujące jednoczenie wszystkie prognozy bazowe w oparciu o modele regresji. Metoda **OLS** nadaje równe wagi każdemu szeregowi. Metoda **WLS** skaluje macierz wag przy pomocy wariancji błędów z poszczególnych szeregów. Natomiast **MinT** optymalizuje kowariancję błędów prognoz z całej struktury, co w literaturze uznawane jest za podejście najbardziej efektywne.

1.3 Miary dokładności prognoz

Ocenę jakości prognoz przeprowadzono w oparciu o zbiór testowy, wykorzystując standardowe w analizie szeregów czasowych metryki błędów:

- **MAE (Mean Absolute Error):** Średni błąd bezwzględny. Wskazuje, o ile jednostek średnio prognoza odchyla się od wartości rzeczywistej. Mniej czuły na wartości odstające.
- **MAPE (Mean Absolute Percentage Error):** Średni bezwzględny błąd procentowy. Wyraża błąd w ujęciu względnym, co ułatwia interpretację. Ma jednak wady przy wartościach rzeczywistych bliskich zeru.
- **MASE (Mean Absolute Scaled Error):** Średni bezwzględny błąd skalowany. Wartości poniżej 1 oznaczają, że badany model radzi sobie lepiej niż model naiwny. Niezbędna miara przy porównywaniu szeregów o różnej skali.
- **RMSE (Root Mean Squared Error):** Pierwiastek błędu średniokwadratowego. Metryka bardzo popularna, jednak silnie penalizująca duże pomyłki (wartości odstające), ze względu na potęgowanie różnic.