Prognozowanie Hierarchicznych Szeregów Czasowych

2026-11-11

Spis treści

1 Cel i zakres opracowania **2**

2 Formalizacja hierarchicznego szeregu czasowego **3**
2.1 Węzły hierarchii, szeregi bazowe i macierz sumowania 3
2.2 Spójność prognoz (*coherence*) 4
2.3 Hierarchie a szeregi grupowe 5

3 Modele generowania prognoz bazowych **5**
3.1 Modele naiwne – Naive i Seasonal Naive 5
3.1.1 Model naiwny (Naive) 5
3.1.2 Model naiwny sezonowy (Seasonal Naive, SNaive) 6
3.1.3 Implementacja w R 6
3.2 Model ETS (Error, Trend, Seasonal) 7
3.2.1 Idea i zapis modelu 7
3.2.2 Przykład: model Holt-Wintersa z komponentami addytywnymi 7
3.2.3 Estymacja i wybór wariantu ETS 8
3.2.4 Implementacja w R 9
3.3 Model ARIMA i sezonowy SARIMA 9
3.3.1 Idea modelu ARIMA 9
3.3.2 Sezonowy model SARIMA 10
3.3.3 Estymacja i dobór rzędów 11
3.3.4 Implementacja w R 11

4 Metody prognozowania i uzgadniania hierarchicznego **12**
4.1 Prognozy bazowe (BASE) – brak uzgadniania 12
4.2 Bottom-Up (BU) 12
4.2.1 Definicja i zapis macierzowy 12
4.2.2 Procedura obliczeniowa 13
4.2.3 Zalety, wady i przydatność 13
4.3 Top-Down (TD) 13
4.3.1 Idea metody 13
4.3.2 Średnie udziały historyczne – metoda A (average proportions) 14
4.3.3 Udziały oparte na średnich historycznych – metoda F (proportion averages) 14

4.3.4 Udziały wyznaczane z prognoz – forecast proportions 14
4.3.5 Zalety, wady i przydatność 15
4.4 Middle-Out (MO) 15
4.5 Uzgadnianie optymalne – wspólny formalizm macierzowy 16
4.5.1 Ogólna postać metody uzgadniania 16
4.5.2 Wariancja błędów prognoz bazowych 16
4.5.3 Wyprowadzenie rozwiązania ważonego 17
4.5.4 OLS – Ordinary Least Squares 17
4.5.5 WLS – Weighted Least Squares 18
4.5.6 MinT – Minimum Trace reconciliation 19
4.5.7 Relacja pomiędzy OLS, WLS i MinT 21
4.5.8 Implementacja metod hierarchicznych w R 22

5 Miary dokładności prognoz **23**
5.1 Definicje ogólne i oznaczenia 23
5.2 MAE – Mean Absolute Error 24
5.3 MAPE – Mean Absolute Percentage Error 24
5.4 MASE – Mean Absolute Scaled Error 25
5.5 RMSE – Root Mean Squared Error 26
5.6 RRMSE – Relative Root Mean Squared Error 27
5.7 RMSSE i WRMSSE – miary uzupełniające dla danych hierarchicznych . . . 27
5.7.1 RMSSE – Root Mean Squared Scaled Error 27
5.7.2 WRMSSE – Weighted Root Mean Squared Scaled Error 28
5.8 Zestawienie miar 28

6 Ocena prognoz w strukturze hierarchicznej **29**
6.1 Porównywanie jakości pomiędzy poziomami 29
6.2 Kontrola spójności jako odrębna diagnostyka 30
6.3 Podział treningowy, testowy i walidacja krocząca 30

7 Rekomendowany schemat eksperymentu **31**

8 Najważniejsze uwagi metodologiczne i ograniczenia **31**

9 Literatura i dokumentacja **32**

1 Cel i zakres opracowania

Celem niniejszego rozdziału jest formalne przedstawienie modeli służących do wyznaczania prognoz bazowych, metod uzgadniania prognoz w strukturze hierarchicznej oraz miar wykorzystywanych do oceny ich jakości. Opis stanowi podstawę metodyczną projektu inżynierskiego **„Prognozowanie Hierarchicznych Szeregów Czasowych”**. Nacisk położono na definicje matematyczne, założenia, procedury obliczeniowe, własności statystyczne oraz praktyczne konsekwencje wyboru poszczególnych rozwiązań.

W dokumencie rozróżnia się dwa etapy procesu prognozowania:

1. **Generowanie prognoz bazowych** (*base forecasts*) – osobne dopasowanie modelu do każdego szeregu występującego w hierarchii.
2. **Uzgadnianie prognoz** (*forecast reconciliation*) – przekształcenie prognoz bazowych tak, aby spełniały relacje agregacyjne narzucone przez strukturę danych.

Rozdzielenie tych etapów jest istotne. Model ETS lub ARIMA opisuje dynamikę pojedynczego szeregu, natomiast Bottom-Up, Top-Down, OLS, WLS i MinT określają, w jaki sposób prognozy dla różnych węzłów hierarchii mają zostać ze sobą połączone. Nie należy zatem utożsamiać modelu generującego prognozę z metodą jej uzgadniania.

Zakładamy przede wszystkim **addytywną strukturę agregacji**, tj. wartość węzła nadrzędnego jest sumą wartości jego węzłów podrzędnych. Jest to standardowy przypadek rozpatrywany w literaturze dotyczącej hierarchicznych i grupowych szeregów czasowych. Jeżeli zmienna wymaga agregacji innej niż suma (np. średniej ważonej, udziału lub ilorazu), należy najpierw zdefiniować odpowiednie ograniczenia; wzory sumowania przedstawione w tym rozdziale nie mogą być automatycznie stosowane do dowolnej zmiennej.

2 Formalizacja hierarchicznego szeregu czasowego

2.1 Węzły hierarchii, szeregi bazowe i macierz sumowania

Niech hierarchia zawiera łącznie n szeregów czasowych, z czego m należy do najniższego poziomu (tzw. *bottom level*). Przyjmijmy, że wektor obserwacji w chwili t ma postać

$$\boldsymbol{y}_t = (y_{1,t}, y_{2,t}, \ldots, y_{n,t})^\top,$$

natomiast wektor szeregów najniższego poziomu:

$$\boldsymbol{b}_t = (b_{1,t}, b_{2,t}, \ldots, b_{m,t})^\top.$$

Zależności agregacyjne można zapisać za pomocą **macierzy sumowania** (*summing matrix*) $\boldsymbol{S}$ o wymiarach $n \times m$:

$$\boxed{\boldsymbol{y}_t = \boldsymbol{S}\boldsymbol{b}_t.}$$

Każdy wiersz macierzy $\boldsymbol{S}$ opisuje sposób otrzymania danego węzła z szeregów najniższego poziomu. W typowej hierarchii element s_{ij} jest równy 1, jeżeli szereg najniższego poziomu j wchodzi w skład węzła i, i 0 w przeciwnym przypadku. Wiersze odpowiadające szeregom najniższego poziomu tworzą macierz jednostkową $\boldsymbol{I}_m$.

Przykładowo, rozważmy hierarchię składającą się z sumy całkowitej T, dwóch regionów A i B oraz czterech produktów: A_1, A_2, B_1, B_2. Przy wektorze szeregów najniższego poziomu $\boldsymbol{b}_t = (y_{A_1,t}, y_{A_2,t}, y_{B_1,t}, y_{B_2,t})^\top$ macierz sumowania wynosi

$$\boldsymbol{S} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \qquad \boldsymbol{y}_t = \begin{bmatrix} y_{T,t} \\ y_{A,t} \\ y_{B,t} \\ y_{A_1,t} \\ y_{A_2,t} \\ y_{B_1,t} \\ y_{B_2,t} \end{bmatrix}.$$

W szczególności:

$$\begin{aligned} y_{T,t} &= y_{A,t} + y_{B,t}, \\ y_{A,t} &= y_{A_1,t} + y_{A_2,t}, \\ y_{B,t} &= y_{B_1,t} + y_{B_2,t}. \end{aligned}$$

Macierz $\boldsymbol{S}$ jest podstawowym obiektem matematycznym całego zagadnienia. Pozwala ona zarówno generować agregaty z prognoz dolnego poziomu, jak i wyznaczać prognozy spójne w wyniku uzgadniania.

2.2 Spójność prognoz (*coherence*)

Prognozy bazowe wyznaczone niezależnie dla każdego szeregu oznaczmy przez

$$\widehat{\boldsymbol{y}}_{T+h|T} = (\hat{y}_{1,T+h|T}, \ldots, \hat{y}_{n,T+h|T})^\top,$$

gdzie T jest ostatnim momentem obserwacji, a h – horyzontem prognozy. Prognozy te nie muszą spełniać relacji agregacyjnych. Przykładowo prognoza całkowita może być różna od sumy prognoz regionów.

Wektor prognoz $\widetilde{\boldsymbol{y}}_{T+h|T}$ jest **spójny** (*coherent*), jeżeli istnieje wektor prognoz dla poziomu najniższego $\widetilde{\boldsymbol{b}}_{T+h|T}$ taki, że

$$\boxed{\widetilde{\boldsymbol{y}}_{T+h|T} = \boldsymbol{S}\widetilde{\boldsymbol{b}}_{T+h|T}.}$$

Równoważnie, wektor prognoz spójnych należy do przestrzeni kolumn macierzy $\boldsymbol{S}$:

$$\widetilde{\boldsymbol{y}}_{T+h|T} \in \mathcal{C}(\boldsymbol{S}).$$

Dla hierarchii z przykładu oznacza to spełnienie równań

$$\tilde{y}_T = \tilde{y}_A + \tilde{y}_B, \qquad \tilde{y}_A = \tilde{y}_{A_1} + \tilde{y}_{A_2}, \qquad \tilde{y}_B = \tilde{y}_{B_1} + \tilde{y}_{B_2}.$$

Spójność nie jest tym samym co dokładność. Prognoza może być spójna, lecz obarczona dużym błędem względem wartości rzeczywistej. Analogicznie prognozy bazowe mogą być dokładne dla poszczególnych węzłów, lecz niespójne między poziomami. W projekcie należy zatem oceniać oba aspekty oddzielnie.

2.3 Hierarchie a szeregi grupowe

W **ściśle hierarchicznej** strukturze każdy węzeł niższego poziomu należy do jednego węzła nadrzędnego na danym poziomie. Przykładem jest podział kraju na województwa, województw na powiaty, a powiatów na gminy.

W **strukturze grupowej** (*grouped time series*) te same szeregi mogą być agregowane według kilku przecinających się klasyfikacji, np. według regionu oraz niezależnie według kategorii produktu. Macierz $\boldsymbol{S}$ nadal może opisywać liniowe ograniczenia agregacyjne, jednak nie zawsze istnieje jednoznaczna ścieżka od korzenia do liścia. Z tego powodu klasyczne metody Top-Down i Middle-Out są naturalne przede wszystkim dla hierarchii drzewiastej, a Bottom-Up i metody macierzowe mogą być stosowane również w strukturach grupowych. Takie rozróżnienie opisano m.in. w *Forecasting: Principles and Practice* oraz dokumentacji pakietu `hts`.

3 Modele generowania prognoz bazowych

3.1 Modele naiwne – Naive i Seasonal Naive

3.1.1 Model naiwny (Naive)

Model naiwny zakłada, że wartość szeregu w przyszłości będzie równa ostatniej zaobserwowanej wartości. Jest to prognoza wynikająca z modelu błądzenia losowego (*random walk*):

$$y_t = y_{t-1} + \varepsilon_t, \qquad E(\varepsilon_t) = 0, \qquad \mathrm{Var}(\varepsilon_t) = \sigma^2.$$

Prognoza punktowa dla dowolnego horyzontu $h \geq 1$ ma postać

$$\boxed{\hat{y}_{T+h|T} = y_T.}$$

Sposób wyznaczenia. W praktyce wystarczy pobrać ostatnią obserwację szeregu i przypisać ją do wszystkich okresów horyzontu prognozy. Nie ma tu parametrów wygładzania ani procesu optymalizacji.

Zalety: bardzo prosta konstrukcja, małe wymagania obliczeniowe, brak ryzyka przeuczenia parametrów, dobry punkt odniesienia dla szeregów bez wyraźnego trendu i sezonowości.

Wady: nie modeluje trendu ani sezonowości; prognoza punktowa jest stała w całym horyzoncie; może być niewystarczająca dla szeregów o silnej dynamice.

Zastosowanie w projekcie. Model powinien być używany jako benchmark dla szeregów bez dominującego wzorca sezonowego. W hierarchii może być dopasowany oddzielnie do wszystkich węzłów (prognozy bazowe) albo do szeregów dolnego poziomu w wariancie Bottom-Up.

3.1.2 Model naiwny sezonowy (Seasonal Naive, SNaive)

Model sezonowy zakłada, że przyszła wartość będzie równa ostatniej zaobserwowanej wartości z analogicznego okresu poprzedniego cyklu sezonowego. Niech m oznacza długość sezonu, np. $m = 12$ dla danych miesięcznych z sezonowością roczną lub $m = 4$ dla kwartalnych danych z sezonowością roczną. Wtedy

$$\boxed{\hat{y}_{T+h|T} = y_{T+h-m\lceil h/m \rceil},}$$

co oznacza powtarzanie ostatniego zaobserwowanego sezonu. Równoważnie, prognoza spełnia rekurencję

$$\hat{y}_{T+h|T} = \begin{cases} y_{T+h-m}, & 1 \leq h \leq m, \\ \hat{y}_{T+h-m|T}, & h > m. \end{cases}$$

Można ją interpretować jako prognozę z sezonowym modelem błądzenia losowego:

$$y_t = y_{t-m} + \varepsilon_t.$$

Sposób wyznaczenia. Dla pierwszych m okresów prognozy kopiowane są wartości z ostatniego zaobserwowanego sezonu. Dla kolejnych sezonów procedura jest powtarzana rekurencyjnie.

Zalety: uwzględnia sezonowość bez estymacji parametrów; stanowi mocny benchmark dla danych o stabilnym wzorcu sezonowym; jest odporna na nadmierne rozbudowanie modelu.

Wady: zakłada niezmienność profilu sezonowego; nie uwzględnia trendu ani zmian poziomu; nie reaguje na zmianę sezonowości w czasie.

Zastosowanie w projekcie. SNaive jest szczególnie ważny dla miesięcznych, kwartalnych lub tygodniowych danych sezonowych. Jest również naturalnym modelem odniesienia w mianowniku sezonowej wersji MASE i RMSSE.

3.1.3 Implementacja w R

W pakiecie `forecast` dostępne są funkcje `naive()` i `snaive()`. W pakiecie `fable` odpowiednikami są `NAIVE()` i `SNAIVE()`.

```
# Pakiet forecast { obiekt ts
library(forecast)
fc_naive  <- forecast::naive(y, h = 12)
fc_snaive <- forecast::snaive(y, h = 12)
```

```r
# Pakiet fable { dane w formacie tsibble
library(fable)
modele <- dane_tsibble |>
  model(
    naive  = NAIVE(wartosc),
    snaive = SNAIVE(wartosc)
  )
prognozy <- modele |> forecast(h = 12)
```

3.2 Model ETS (Error, Trend, Seasonal)

3.2.1 Idea i zapis modelu

ETS jest rodziną modeli wygładzania wykładniczego przedstawioną w postaci modeli przestrzeni stanów. Nazwa modelu składa się z trzech oznaczeń $ETS(E, T, S)$:

- E – składnik błędu (*Error*): addytywny A lub multiplikatywny M;
- T – składnik trendu (*Trend*): brak N, addytywny A lub addytywny tłumiony Ad (w implementacjach mogą występować także inne warianty);
- S – składnik sezonowy (*Seasonal*): brak N, addytywny A lub multiplikatywny M.

Przykładowo $ETS(A, A, N)$ oznacza model z błędem addytywnym, trendem addytywnym i bez sezonowości, natomiast $ETS(A, A, M)$ – model z błędem addytywnym, trendem addytywnym oraz sezonowością multiplikatywną.

Wygładzanie wykładnicze przypisuje większe wagi nowszym obserwacjom. W najprostszym modelu wygładzania prostego $ETS(A, N, N)$:

$$\begin{aligned} y_t &= \ell_{t-1} + \varepsilon_t, \\ \ell_t &= \ell_{t-1} + \alpha\varepsilon_t, \end{aligned}$$

gdzie ℓ_t jest poziomem szeregu, ε_t – błędem jednokrokowym, a $\alpha \in (0, 1)$ – parametrem wygładzania. Ponieważ $\hat{y}_{t|t-1} = \ell_{t-1}$, aktualizacja poziomu jest równoważna

$$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}.$$

Widać zatem, że ostatnia obserwacja otrzymuje wagę α, a starsze obserwacje wpływają na poziom przez malejący geometrycznie ciąg wag.

3.2.2 Przykład: model Holt-Wintersa z komponentami addytywnymi

Dla szeregu z trendem i sezonowością addytywną model $ETS(A, A, A)$ można zapisać jako

$$y_t = \ell_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t,$$

$$\ell_t = \ell_{t-1} + b_{t-1} + \alpha\varepsilon_t,$$
$$b_t = b_{t-1} + \beta\varepsilon_t,$$
$$s_t = s_{t-m} + \gamma\varepsilon_t,$$

gdzie:

- ℓ_t – lokalny poziom szeregu,
- b_t – lokalny trend,
- s_t – składnik sezonowy,
- m – długość sezonu,
- α, β, γ – parametry wygładzania,
- ε_t – innowacja, czyli różnica pomiędzy obserwacją a prognozą jednokrokową.

Dla modelu z trendem addytywnym bez sezonowości ($ETS(A, A, N)$) pomija się składnik s_{t-m}. Prognoza horyzontu h ma wtedy postać

$$\hat{y}_{T+h|T} = \ell_T + hb_T.$$

W modelu z trendem tłumionym (*damped trend*) wpływ trendu maleje z horyzontem. Przy parametrze tłumienia $\phi \in (0, 1)$ prognoza wynosi

$$\hat{y}_{T+h|T} = \ell_T + \left(\sum_{j=1}^{h} \phi^j\right) b_T = \ell_T + \frac{\phi(1-\phi^h)}{1-\phi} b_T.$$

W przypadku sezonowości multiplikatywnej wpływ sezonu jest proporcjonalny do poziomu szeregu. Przykładowa postać równania obserwacji to

$$y_t = (\ell_{t-1} + b_{t-1})s_{t-m} + \varepsilon_t.$$

Sezonowość multiplikatywna jest często użyteczna, gdy amplituda wahań sezonowych rośnie wraz z poziomem szeregu. Modele multiplikatywne wymagają jednak szczególnej ostrożności dla danych zerowych lub ujemnych.

3.2.3 Estymacja i wybór wariantu ETS

Parametry wygładzania oraz stany początkowe wyznacza się przez optymalizację funkcji wiarygodności w reprezentacji przestrzeni stanów (w zależności od wariantu i implementacji dostępne są także inne kryteria optymalizacji). Następnie wariant modelu można wybrać na podstawie kryterium informacyjnego, najczęściej skorygowanego kryterium Akaikego:

$$AIC_c = -2\log L + 2k\frac{N}{N-k-1},$$

gdzie L oznacza maksymalną wartość funkcji wiarygodności, k – liczbę estymowanych parametrów, a N – liczbę obserwacji wykorzystanych do estymacji. Niższa wartość AIC_c oznacza lepszy kompromis pomiędzy wiarygodnością dopasowania a złożonością modelu. Przy porównywaniu modeli należy stosować to samo kryterium i ten sam zbiór obserwacji.

W praktyce automatyczny wybór ETS analizuje dopuszczalne kombinacje błędu, trendu i sezonowości oraz warianty trendu tłumionego. Nie oznacza to jednak, że wybrany model będzie zawsze najlepszy na zbiorze testowym – kryterium informacyjne jest kryterium dopasowania do próby uczącej, a nie bezpośrednią miarą błędu prognozy poza próbą.

Zalety: elastyczne modelowanie poziomu, trendu i sezonowości; stosunkowo łatwa interpretacja komponentów; możliwość uzyskania prognoz punktowych i przedziałowych; automatyczny dobór wariantu i parametrów; często dobra skuteczność dla szeregów o stabilnych wzorcach.

Wady: klasyczny ETS nie wprowadza bezpośrednio zmiennych objaśniających; może reagować z opóźnieniem na gwałtowne zmiany strukturalne; przy krótkich szeregach dobór wielu komponentów bywa niestabilny; warianty multiplikatywne są problematyczne przy zerach i wartościach ujemnych.

Zastosowanie w projekcie. ETS będzie jednym z podstawowych modeli bazowych. Warto porównywać jego prognozy na poziomie agregatów i na poziomie najniższym, ponieważ wzorce sezonowe i trend mogą być odmienne w różnych węzłach hierarchii. Agregacja może wygładzać część wahań widocznych na poziomie szczegółowym.

3.2.4 Implementacja w R

W pakiecie `forecast` model automatycznie wybierany jest przez `ets()` przy ustawieniu `model = "ZZZ"` (ustawienie domyślne). Argument `ic` pozwala wybrać kryterium informacyjne, np. `"aicc"`. W pakiecie `fable` analogiczną rolę pełni `ETS()`.

```
# forecast
fit_ets <- forecast::ets(y, model = "ZZZ", ic = "aicc")
fc_ets  <- forecast::forecast(fit_ets, h = 12)

# fable
fit_ets_fable <- dane_tsibble |>
  model(ets = ETS(wartosc))
fc_ets_fable <- fit_ets_fable |> forecast(h = 12)
```

W `forecast::ets()` można jawnie wskazać model, np. `model = "ANN"`, `model = "AAN"` lub `model = "AAA"`. Jawna specyfikacja jest użyteczna, gdy chcemy porównać określone struktury, a nie tylko wynik procedury automatycznej.

3.3 Model ARIMA i sezonowy SARIMA

3.3.1 Idea modelu ARIMA

Model ARIMA (*Autoregressive Integrated Moving Average*) łączy trzy mechanizmy:

- autoregresję (AR) – zależność bieżącej wartości od wcześniejszych wartości szeregu,
- różnicowanie (I) – usuwanie niestacjonarności poprzez różnice,
- średnią ruchomą (MA) – zależność od bieżących i przeszłych składników losowych.

Model ARIMA(p, d, q) można zapisać z wykorzystaniem operatora opóźnień B, dla którego $By_t = y_{t-1}$:

$$\boxed{\phi(B)(1-B)^d y_t = c + \theta(B)\varepsilon_t,}$$

gdzie

$$\phi(B) = 1 - \phi_1 B - \cdots - \phi_p B^p, \qquad \theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q.$$

Parametry p, d, q oznaczają odpowiednio rząd części autoregresyjnej, liczbę różnicowań oraz rząd części średniej ruchomej. Konkretna konwencja znaków przy współczynnikach MA może zależeć od zapisu stosowanego w publikacji lub oprogramowaniu; kluczowa jest spójność przy interpretacji parametrów.

Po zróżnicowaniu szereg

$$z_t = (1-B)^d y_t$$

powinien spełniać założenia stacjonarności wymagane przez model ARMA. W szczególności jego średnia i wariancja nie powinny systematycznie zależeć od czasu, a autokowariancja powinna zależeć od odległości czasowej, a nie od bezwzględnego położenia obserwacji.

3.3.2 Sezonowy model SARIMA

Dla danych o sezonowości długości m stosuje się rozszerzenie SARIMA:

$$\boxed{\phi(B)\Phi(B^m)(1-B)^d(1-B^m)^D y_t = c + \theta(B)\Theta(B^m)\varepsilon_t,}$$

gdzie P, D, Q oznaczają odpowiednio sezonowe rzędy AR, różnicowania i MA, a m jest długością sezonu. Pełna notacja ma postać

$$ARIMA(p, d, q)(P, D, Q)_m.$$

Różnicowanie zwykłe $(1-B)^d$ usuwa niestacjonarność niesezonową, natomiast różnicowanie sezonowe $(1-B^m)^D$ służy do usuwania sezonowych pierwiastków jednostkowych. Nie należy automatycznie zwiększać rzędów różnicowania – nadmierne różnicowanie może zwiększać wariancję i wprowadzać sztuczną strukturę autokorelacji.

3.3.3 Estymacja i dobór rzędów

Parametry modelu ARIMA szacuje się zazwyczaj metodą największej wiarygodności (ML), niekiedy z wykorzystaniem sum kwadratów warunkowych do wyznaczenia wartości początkowych. Dobór rzędów polega na znalezieniu kombinacji (p, d, q, P, D, Q), która spełnia ograniczenia modelu i osiąga korzystną wartość kryterium informacyjnego, np. AIC_c lub BIC.

Funkcja `auto.arima()` z pakietu `forecast` automatyzuje ten proces. W zależności od argumentów stosuje testy do określenia stopnia różnicowania, a następnie przeszukuje przestrzeń modeli. Domyślne przeszukiwanie krokowe (*stepwise*) jest szybsze, lecz nie musi sprawdzić wszystkich możliwych kombinacji. Ustawienie `stepwise = FALSE` i `approximation = FALSE` zwiększa zakres poszukiwań i dokładność porównania, ale może znacznie wydłużyć czas obliczeń.

Po dopasowaniu modelu należy przeprowadzić diagnostykę reszt. Oczekuje się, że reszty będą miały średnią bliską zeru i nie będą wykazywały istotnej pozostałej autokorelacji. Pomocne są wykresy ACF reszt, test Ljunga–Boxa oraz funkcja `checkresiduals()` z pakietu `forecast`. Niespełnienie warunków diagnostycznych wskazuje, że model nie wyjaśnia całej struktury czasowej danych.

Zalety: elastyczne modelowanie zależności autokorelacyjnych; możliwość uwzględnienia różnicowania zwykłego i sezonowego; szerokie podstawy teoretyczne; możliwość rozszerzenia o regresory zewnętrzne w modelach ARIMAX/SARIMAX.

Wady: konieczność poprawnego określenia stacjonarności i rzędów modelu; większa złożoność interpretacji niż w prostych modelach wygładzania; ryzyko niestabilnego dopasowania w krótkich szeregach; dobór automatyczny nie gwarantuje globalnie najlepszego wariantu ani najlepszej jakości poza próbą.

Zastosowanie w projekcie. ARIMA będzie drugim podstawowym modelem bazowym, pozwalającym porównać podejście oparte na autokorelacji z ETS. Model może być dopasowany niezależnie w każdym węźle hierarchii. Warto sprawdzić, czy agregaty oraz szeregi najniższego poziomu wymagają innych rzędów różnicowania i innych parametrów sezonowych.

3.3.4 Implementacja w R

```r
# forecast
fit_arima <- forecast::auto.arima(
  y,
  seasonal = TRUE,
  ic = "aicc",
  stepwise = FALSE,
  approximation = FALSE
)
fc_arima <- forecast::forecast(fit_arima, h = 12)
forecast::checkresiduals(fit_arima)
```

```r
# fable
fit_arima_fable <- dane_tsibble |>
  model(arima = ARIMA(wartosc))
fc_arima_fable <- fit_arima_fable |> forecast(h = 12)
```

W `auto.arima()` argumenty `max.p`, `max.q`, `max.P`, `max.Q`, `max.d` i `max.D` ograniczają przestrzeń poszukiwanych modeli. Parametr `xreg` umożliwia wprowadzenie zmiennych objaśniających, o ile ich przyszłe wartości są znane lub można je prognozować.

4 Metody prognozowania i uzgadniania hierarchicznego

4.1 Prognozy bazowe (BASE) – brak uzgadniania

Metoda BASE oznacza, że prognozy bazowe z modeli ETS, ARIMA lub Naive pozostają niezmienione. Dla każdego węzła i wyznaczana jest prognoza

$$\hat{y}_{i,T+h|T} = f_i(\mathcal{I}_T),$$

gdzie f_i może być innym modelem dla każdego szeregu, a $\mathcal{I}_T$ oznacza informację dostępną do chwili T.

Wektor prognoz bazowych $\widehat{\boldsymbol{y}}_{T+h|T}$ nie musi należeć do $\mathcal{C}(\boldsymbol{S})$. W konsekwencji na ogół

$$\hat{y}_{\text{agregat},T+h|T} \neq \sum_{j \in \text{dzieci}} \hat{y}_{j,T+h|T}.$$

Sposób wyznaczenia. Dopasowuje się wybrany model do każdego szeregu i odczytuje prognozy na zadany horyzont. Nie wykonuje się dodatkowego przekształcenia z użyciem macierzy $\boldsymbol{S}$.

Zalety: zachowuje indywidualne prognozy każdego węzła; jest prostym punktem odniesienia do oceny wpływu uzgadniania; nie wymaga estymacji macierzy kowariancji ani udziałów.

Wady: brak gwarancji spójności; prognozy na różnych poziomach mogą prowadzić do sprzecznych decyzji; wyniki nie tworzą jednej zgodnej agregacyjnie prognozy całej struktury.

Zastosowanie w projekcie. BASE powinien stanowić punkt odniesienia dla wszystkich metod uzgadniania. Umożliwia odpowiedź na pytanie, czy wymuszenie spójności poprawia, czy pogarsza dokładność na poszczególnych poziomach.

4.2 Bottom-Up (BU)

4.2.1 Definicja i zapis macierzowy

Metoda Bottom-Up polega na prognozowaniu wyłącznie szeregów z najniższego poziomu hierarchii, a następnie agregowaniu prognoz do poziomów wyższych. Najpierw wyznacza się

$$\hat{\boldsymbol{b}}_{T+h|T} = \left(\hat{b}_{1,T+h|T}, \ldots, \hat{b}_{m,T+h|T}\right)^{\top}.$$

Następnie prognozę całej hierarchii otrzymuje się przez przemnożenie przez macierz sumowania:

$$\boxed{\widetilde{\boldsymbol{y}}^{BU}_{T+h|T} = \boldsymbol{S}\hat{\boldsymbol{b}}_{T+h|T}.}$$

Wynik jest spójny z definicji, ponieważ należy do przestrzeni kolumn macierzy $\boldsymbol{S}$.

4.2.2 Procedura obliczeniowa

1. Wyodrębnić m szeregów najniższego poziomu.
2. Dopasować do każdego z nich wybrany model (np. ETS, ARIMA lub SNaive).
3. Wygenerować prognozy na wspólny horyzont h.
4. Pomnożyć wektor prognoz dolnego poziomu przez $\boldsymbol{S}$.
5. Otrzymać spójne prognozy dla wszystkich węzłów.

4.2.3 Zalety, wady i przydatność

Zalety: pełne wykorzystanie informacji z poziomu szczegółowego; nie wymaga estymowania udziałów ani macierzy kowariancji; łatwa implementacja; gwarantowana spójność; naturalne rozwiązanie dla struktur grupowych, w których nie można zastosować klasycznego Top-Down.

Wady: błędy prognoz na poziomie dolnym kumulują się w agregatach; metoda nie wykorzystuje bezpośrednio informacji zawartej w historycznej trajektorii agregatów; bardzo zaszumione szeregi najniższego poziomu mogą pogarszać jakość prognoz wyższych poziomów.

Zastosowanie w projekcie. BU będzie podstawową metodą uzgadniania i ważnym benchmarkiem dla metod OLS/WLS/MinT. Jest szczególnie uzasadniona, gdy najważniejszy jest poziom szczegółowy, a agregaty mają być dokładnie sumą prognoz składowych.

4.3 Top-Down (TD)

4.3.1 Idea metody

Metoda Top-Down rozpoczyna od prognozy szeregu zagregowanego (korzenia hierarchii), a następnie rozdziela ją pomiędzy węzły podrzędne na podstawie udziałów (*disaggregation proportions*). Dla struktury dwupoziomowej, w której $\hat{y}_{T+h|T}$ oznacza prognozę całkowitą, a $\boldsymbol{p} = (p_1, \ldots, p_m)^{\top}$ – wektor udziałów, prognozy dolnego poziomu wynoszą

$$\widetilde{\boldsymbol{b}}^{TD}_{T+h|T} = \boldsymbol{p}\hat{y}_{T+h|T}, \qquad \sum_{j=1}^{m} p_j = 1.$$

Prognoza całej hierarchii ma wtedy postać

$$\boxed{\tilde{\boldsymbol{y}}^{TD}_{T+h|T} = \boldsymbol{S}\boldsymbol{p}\hat{y}_{T+h|T}.}$$

W hierarchii wielopoziomowej podział wykonywany jest kolejno dla każdego węzła nadrzędnego. Udziały potomków tego samego rodzica powinny sumować się do jedności.

4.3.2 Średnie udziały historyczne – metoda A (average proportions)

Niech $y_{j,t}$ oznacza historyczną wartość szeregu dolnego poziomu j, a y_t – odpowiadającą mu wartość agregatu nadrzędnego. Średni udział historyczny zdefiniowany jest jako

$$\boxed{p_j^{(A)} = \frac{1}{T}\sum_{t=1}^{T}\frac{y_{j,t}}{y_t}.}$$

Procedura polega na obliczeniu udziału w każdym historycznym okresie, a następnie uśrednieniu tych udziałów. Każdy okres otrzymuje taką samą wagę, niezależnie od wielkości sprzedaży czy wartości agregatu w danym okresie.

4.3.3 Udziały oparte na średnich historycznych – metoda F (proportion averages)

Alternatywnie można obliczyć udział jako stosunek sum (równoważnie: stosunek średnich arytmetycznych):

$$\boxed{p_j^{(F)} = \frac{\sum_{t=1}^{T} y_{j,t}}{\sum_{t=1}^{T} y_t}.}$$

Metoda A uśrednia ilorazy okresowe, natomiast metoda F najpierw sumuje wartości, a następnie oblicza ich relację. W konsekwencji metoda F nadaje większy wpływ okresom, w których wartość agregatu jest większa. Obie metody prowadzą do różnych wyników, jeżeli poziom agregatu wyraźnie zmienia się w czasie.

4.3.4 Udziały wyznaczane z prognoz – forecast proportions

W metodzie udziałów prognozowych proporcje nie są wyznaczane wyłącznie na podstawie historii. Najpierw oblicza się prognozy bazowe dla węzłów, a następnie udział prognozy danego potomka w sumie prognoz potomków jego rodzica. Dla pojedynczego podziału:

$$p_j^{(h)} = \frac{\hat{y}_{j,T+h|T}}{\sum_{k\in\mathcal{C}(j_0)}\hat{y}_{k,T+h|T}},$$

gdzie $\mathcal{C}(j_0)$ oznacza zbiór dzieci tego samego rodzica. Dla wielopoziomowej hierarchii udział końcowego liścia otrzymuje się jako iloczyn udziałów na kolejnych odcinkach ścieżki od korzenia do danego liścia. Dzięki temu udziały mogą zmieniać się z horyzontem prognozy.

4.3.5 Zalety, wady i przydatność

Zalety: niewielka liczba modeli (w skrajnym wariancie modeluje się tylko szereg całkowity); ograniczenie wpływu szumu na poziomie szczegółowym; prosta interpretacja udziałów; może być przydatna w przypadku bardzo krótkich lub niestabilnych szeregów dolnego poziomu.

Wady: utrata informacji o specyficznych wzorcach poszczególnych szeregów; udziały historyczne mogą nie odzwierciedlać przyszłych zmian struktury; metoda może być obciążona na niższych poziomach, jeżeli proporcje zmieniają się w czasie; klasyczny Top-Down wymaga drzewa hierarchicznego i nie przenosi się bezpośrednio na dowolne struktury grupowe.

Zastosowanie w projekcie. TD warto uwzględnić jako metodę porównawczą, szczególnie jeżeli najważniejsza jest prognoza łączna albo szeregi najniższego poziomu są bardzo zaszumione. Należy porównać co najmniej metodę A i F, a w razie dostępności prognoz bazowych również udziały prognozowe.

Uwagi numeryczne. Udziały wymagają poprawnego mianownika. Jeżeli agregat jest równy zero, udziały okresowe mogą być nieokreślone. W przypadku ujemnych wartości, zwrotów, sald lub danych z kompensującymi się składnikami udziały mogą wykraczać poza przedział $[0, 1]$ i tracić intuicyjną interpretację. Nie należy bezrefleksyjnie usuwać takich obserwacji ani zastępować mianownika małą stałą – sposób postępowania trzeba uzasadnić właściwościami badanej zmiennej.

4.4 Middle-Out (MO)

Metoda Middle-Out łączy podejście Bottom-Up i Top-Down. Wybierany jest poziom pośredni hierarchii, dla którego wyznacza się prognozy bezpośrednio. Od tego poziomu:

- w kierunku poziomów wyższych stosuje się agregację Bottom-Up,
- w kierunku poziomów niższych stosuje się dezagregację Top-Down.

Niech L oznacza wybrany poziom pośredni, a $\hat{\boldsymbol{y}}^{(L)}_{T+h|T}$ – prognozy dla węzłów na tym poziomie. Dla węzła nadrzędnego a prognoza jest sumą prognoz węzłów poziomu L, które do niego należą:

$$\tilde{y}^{MO}_{a,T+h|T} = \sum_{j \in \mathcal{D}_L(a)} \hat{y}_{j,T+h|T},$$

gdzie $\mathcal{D}_L(a)$ jest zbiorem potomków węzła a na poziomie L. Poniżej poziomu L prognozy rozdzielane są według udziałów, analogicznie jak w metodzie Top-Down.

Procedura obliczeniowa: wybrać poziom pośredni; dopasować modele do szeregów na tym poziomie; wygenerować prognozy; zagregować je do góry; następnie rozdzielić prognozy na poziomy niższe według udziałów. Wynik jest spójny, jeżeli każda operacja agregacji i dezagregacji zachowuje lokalne relacje sumowania.

Zalety: kompromis pomiędzy informacją z poziomu szczegółowego a stabilnością agregatów; możliwość wyboru poziomu najlepiej opisującego strukturę danych; mniejsza liczba prognoz do modelowania niż w pełnym podejściu bazowym.

Wady: wynik zależy od arbitralnego wyboru poziomu pośredniego; wymaga sensownej struktury drzewiastej; część informacji z poziomów pominiętych jest odtwarzana pośrednio poprzez udziały.

Zastosowanie w projekcie. MO może być użyteczne, gdy poziom najniższy jest bardzo zaszumiony, a poziom całkowity zbyt zagregowany, by uchwycić lokalne różnice. Wybór poziomu L powinien być uzasadniony merytorycznie i porównany w walidacji kroczącej.

4.5 Uzgadnianie optymalne – wspólny formalizm macierzowy

4.5.1 Ogólna postać metody uzgadniania

Metody OLS, WLS i MinT wykorzystują prognozy bazowe ze wszystkich poziomów hierarchii. Ich wspólną ideą jest przekształcenie niekoniecznie spójnego wektora prognoz bazowych w wektor należący do przestrzeni kolumn macierzy $\boldsymbol{S}$.

Niech $\boldsymbol{G}$ będzie macierzą wymiaru $m \times n$. Ogólna liniowa metoda uzgadniania ma postać

$$\boxed{\widetilde{\boldsymbol{y}}_{T+h|T} = \boldsymbol{S}\boldsymbol{G}\widehat{\boldsymbol{y}}_{T+h|T}.}$$

Macierz $\boldsymbol{G}$ przekształca prognozy bazowe do prognoz poziomu najniższego, a następnie $\boldsymbol{S}$ odtwarza prognozy wszystkich poziomów. Spójność jest zapewniona przez lewostronne mnożenie przez $\boldsymbol{S}$.

Ważnym warunkiem zachowania prognoz, które już są spójne, jest

$$\boxed{\boldsymbol{S}\boldsymbol{G}\boldsymbol{S} = \boldsymbol{S}.}$$

Jeżeli prognozy bazowe są nieobciążone, a powyższy warunek jest spełniony, uzgadnianie zachowuje nieobciążoność. Nie oznacza to jednak, że dowolny wybór $\boldsymbol{G}$ minimalizuje wariancję błędu.

4.5.2 Wariancja błędów prognoz bazowych

Dla horyzontu h zdefiniujmy wektor błędów prognoz bazowych:

$$\boldsymbol{e}_{T+h|T} = \boldsymbol{y}_{T+h} - \widehat{\boldsymbol{y}}_{T+h|T}.$$

Macierz kowariancji tych błędów oznaczmy przez

$$\boldsymbol{W}_h = \mathrm{Var}(\boldsymbol{e}_{T+h|T}).$$

Macierz $\boldsymbol{W}_h$ opisuje zarówno zróżnicowanie wariancji błędów poszczególnych szeregów (elementy diagonalne), jak i zależności pomiędzy błędami prognoz różnych węzłów (elementy

pozadiagonalne). Jest to istotne, ponieważ błędy prognoz np. regionów mogą być skorelowane wskutek wspólnych szoków gospodarczych lub sezonowych.

W dalszej części przyjmuje się, że macierz $\boldsymbol{W}_h$ jest dodatnio określona lub że w razie osobliwości stosuje się odpowiednią regularizację albo uogólnioną odwrotność.

W sensie teoretycznym $\boldsymbol{W}_h$ jest kowariancją **błędów prognoz wielokrokowych o horyzoncie** h. W praktyce często przybliża się ją kowariancją reszt jednokrokowych, ewentualnie zakładając proporcjonalność $\boldsymbol{W}_h = k_h \boldsymbol{W}_1$. Jeżeli liczba obserwacji na to pozwala, trafniejszym przybliżeniem mogą być błędy prognoz z walidacji kroczącej wyznaczone dla konkretnego horyzontu. Ich estymacja również musi być wykonana bez wykorzystania właściwego zbioru testowego.

4.5.3 Wyprowadzenie rozwiązania ważonego

Wspólną postać OLS/WLS/MinT można również otrzymać, szukając takiego wektora wartości dolnego poziomu $\widetilde{\boldsymbol{b}}$, który jest najbliższy prognozom bazowym w metryce określonej przez macierz wag $\boldsymbol{W}_h^{-1}$. Rozważmy zadanie

$$\widetilde{\boldsymbol{b}}_{T+h|T} = \arg\min_{\boldsymbol{b}} \left(\widehat{\boldsymbol{y}}_{T+h|T} - \boldsymbol{S}\boldsymbol{b}\right)^{\top} \boldsymbol{W}_h^{-1} \left(\widehat{\boldsymbol{y}}_{T+h|T} - \boldsymbol{S}\boldsymbol{b}\right).$$

Różniczkując funkcję celu względem $\boldsymbol{b}$ i przyrównując gradient do zera, otrzymujemy równanie normalne

$$-2\boldsymbol{S}^{\top}\boldsymbol{W}_h^{-1}\left(\widehat{\boldsymbol{y}}_{T+h|T} - \boldsymbol{S}\boldsymbol{b}\right) = \boldsymbol{0},$$

a zatem

$$\boldsymbol{S}^{\top}\boldsymbol{W}_h^{-1}\boldsymbol{S}\,\widetilde{\boldsymbol{b}}_{T+h|T} = \boldsymbol{S}^{\top}\boldsymbol{W}_h^{-1}\widehat{\boldsymbol{y}}_{T+h|T}.$$

Jeżeli macierz $\boldsymbol{S}^{\top}\boldsymbol{W}_h^{-1}\boldsymbol{S}$ jest odwracalna, to

$$\widetilde{\boldsymbol{b}}_{T+h|T} = (\boldsymbol{S}^{\top}\boldsymbol{W}_h^{-1}\boldsymbol{S})^{-1}\boldsymbol{S}^{\top}\boldsymbol{W}_h^{-1}\widehat{\boldsymbol{y}}_{T+h|T}.$$

Po ponownym zagregowaniu przez $\boldsymbol{S}$ otrzymujemy ogólny wzór uzgadniania. Dla $\boldsymbol{W}_h = \boldsymbol{I}$ jest to projekcja OLS; dla diagonalnej macierzy wariancji – WLS; dla pełnej macierzy kowariancji błędów prognoz – wariant MinT. W praktycznych obliczeniach nie zaleca się jawnego wyznaczania odwrotności macierzy, jeżeli można rozwiązać odpowiedni układ równań liniowych metodą stabilną numerycznie.

4.5.4 OLS – Ordinary Least Squares

Wariant OLS przyjmuje, że błędy bazowe mają jednakową wariancję i są nieskorelowane. Formalnie:

$$\boldsymbol{W}_h = k_h \boldsymbol{I}_n, \qquad k_h > 0.$$

Współczynnik k_h nie wpływa na końcową macierz uzgadniania, ponieważ znika podczas obliczania iloczynów macierzy. Otrzymujemy

$$\boxed{\boldsymbol{G}_{OLS} = (\boldsymbol{S}^\top \boldsymbol{S})^{-1} \boldsymbol{S}^\top, \qquad \widetilde{\boldsymbol{y}}^{OLS} = \boldsymbol{S}(\boldsymbol{S}^\top \boldsymbol{S})^{-1} \boldsymbol{S}^\top \widehat{\boldsymbol{y}}.}$$

Jest to projekcja ortogonalna (w sensie geometrii euklidesowej) wektora prognoz bazowych na przestrzeń kolumn $\boldsymbol{S}$. W praktyce OLS traktuje odchylenia prognoz z każdego węzła jednakowo, niezależnie od tego, czy szereg jest mały, czy ma dużą skalę i wariancję.

Sposób obliczenia: utworzyć $\boldsymbol{S}$, obliczyć macierz $(\boldsymbol{S}^\top \boldsymbol{S})^{-1} \boldsymbol{S}^\top$, przemnożyć nią wektor prognoz bazowych, a otrzymany wektor dolnego poziomu ponownie zagregować przez $\boldsymbol{S}$.

Zalety: prostota; brak konieczności estymacji kowariancji; małe wymagania dotyczące danych resztowych; stabilny punkt odniesienia dla metod optymalnego uzgadniania.

Wady: pomija różnice wariancji i korelacje błędów; może nadmiernie korygować prognozy szeregów o dużej wariancji i niedostatecznie wykorzystywać informację z szeregów bardziej precyzyjnych.

Zastosowanie w projekcie. OLS jest podstawowym wariantem macierzowym oraz punktem porównania dla WLS i MinT. Jego prostota jest cenna przy ograniczonej liczbie obserwacji, gdy estymacja pełnej macierzy kowariancji byłaby niestabilna.

4.5.5 WLS – Weighted Least Squares

WLS uogólnia OLS, dopuszczając różne wariancje błędów poszczególnych szeregów. Najczęściej zakłada się, że błędy są nieskorelowane, ale mają różne wariancje:

$$\boldsymbol{W}_h = \operatorname{diag}(w_1, \ldots, w_n).$$

W ogólnym zapisie ważonej metody najmniejszych kwadratów otrzymujemy

$$\boxed{\boldsymbol{G}_{WLS} = (\boldsymbol{S}^\top \boldsymbol{W}_h^{-1} \boldsymbol{S})^{-1} \boldsymbol{S}^\top \boldsymbol{W}_h^{-1}, \qquad \widetilde{\boldsymbol{y}}^{WLS} = \boldsymbol{S}\boldsymbol{G}_{WLS} \widehat{\boldsymbol{y}}.}$$

W praktyce spotykane są co najmniej dwa sposoby określenia wag.

WLS z wagami wariancyjnymi (variance scaling). Przyjmuje się

$$\boldsymbol{W}_h = \operatorname{diag}(\hat{\sigma}_1^2, \ldots, \hat{\sigma}_n^2),$$

gdzie $\hat{\sigma}_i^2$ jest oszacowaniem wariancji błędów modelu dla szeregu i, wyznaczonym np. na podstawie reszt dopasowania. Szeregi o większej wariancji otrzymują mniejszy wpływ w

kryterium ważonych najmniejszych kwadratów, ponieważ ich wkład jest skalowany przez $1/\hat{\sigma}_i^2$.

WLS ze skalowaniem strukturalnym (structural scaling). Gdy nie ma wiarygodnych reszt do oszacowania wariancji, można przyjąć

$$\boldsymbol{W}_h = \operatorname{diag}(\boldsymbol{S}\mathbf{1}_m),$$

gdzie $\mathbf{1}_m$ jest wektorem jedynek długości m. Element diagonalny odpowiada wówczas liczbie szeregów dolnego poziomu składających się na dany węzeł. Założenie to odpowiada sytuacji, w której błędy dolnego poziomu mają jednakową wariancję i są nieskorelowane.

Zalety: uwzględnia zróżnicowanie niepewności pomiędzy szeregami; variance scaling może poprawiać uzgadnianie względem OLS, jeżeli oszacowania wariancji są wiarygodne; wariant strukturalny nie wymaga reszt.

Wady: klasyczny WLS pomija korelacje pomiędzy błędami; oszacowania wariancji mogą być niestabilne przy krótkich próbach; wariant strukturalny opiera się na uproszczonym założeniu o jednakowym wkładzie dolnych szeregów.

Zastosowanie w projekcie. WLS należy potraktować jako pośredni wariant pomiędzy OLS i MinT. Szczególnie przydatne będzie porównanie wersji wariancyjnej z OLS, ponieważ pozwoli ocenić, czy samo uwzględnienie odmiennych wariancji błędów poprawia jakość uzgodnionych prognoz.

4.5.6 MinT – Minimum Trace reconciliation

4.5.6.1 Idea optymalizacji Metoda MinT zaproponowana przez Wickramasuriya, Athanasopoulos i Hyndmana (2019) szuka takiej liniowej metody uzgadniania, która minimalizuje ślad macierzy kowariancji błędów prognoz uzgodnionych. Przyjmując

$$\widetilde{\boldsymbol{y}}_{T+h|T} = \boldsymbol{S}\boldsymbol{G}\widehat{\boldsymbol{y}}_{T+h|T},$$

oraz nieobciążoność prognoz bazowych, kowariancję błędów prognoz uzgodnionych można zapisać jako

$$\boldsymbol{V}_h = \boldsymbol{S}\boldsymbol{G}\boldsymbol{W}_h\boldsymbol{G}^\top\boldsymbol{S}^\top.$$

MinT rozwiązuje zadanie

$$\boxed{\min_{\boldsymbol{G}} \ \operatorname{tr}\left(\boldsymbol{S}\boldsymbol{G}\boldsymbol{W}_h\boldsymbol{G}^\top\boldsymbol{S}^\top\right) \quad \text{przy warunku} \quad \boldsymbol{S}\boldsymbol{G}\boldsymbol{S} = \boldsymbol{S}.}$$

Funkcja celu jest równa sumie wariancji błędów prognoz uzgodnionych wszystkich n szeregów:

$$\operatorname{tr}(\boldsymbol{V}_h) = \sum_{i=1}^{n} \operatorname{Var}\left(\tilde{y}_{i,T+h|T} - y_{i,T+h}\right).$$

Przy odpowiednich założeniach rozwiązanie ma postać zamkniętą:

$$\boxed{\boldsymbol{G}_{MinT} = (\boldsymbol{S}^\top \boldsymbol{W}_h^{-1} \boldsymbol{S})^{-1} \boldsymbol{S}^\top \boldsymbol{W}_h^{-1}.}$$

A więc prognozy uzgodnione wynoszą

$$\boxed{\widetilde{\boldsymbol{y}}_{T+h|T}^{MinT} = \boldsymbol{S}(\boldsymbol{S}^\top \boldsymbol{W}_h^{-1} \boldsymbol{S})^{-1} \boldsymbol{S}^\top \boldsymbol{W}_h^{-1} \widehat{\boldsymbol{y}}_{T+h|T}.}$$

Formalnie wzór ma tę samą postać co uogólniony wariant WLS. O różnicy między metodami decyduje sposób określenia $\boldsymbol{W}_h$. W MinT wykorzystywana jest pełna struktura kowariancji błędów prognoz bazowych, a nie tylko wariancje na przekątnej.

4.5.6.2 Estymacja macierzy kowariancji W praktyce macierz $\boldsymbol{W}_h$ nie jest znana i musi zostać oszacowana na podstawie danych treningowych. Jeżeli dla kolejnych chwil dostępne są zsynchronizowane wektory reszt $\boldsymbol{e}_t = (e_{1,t}, \ldots, e_{n,t})^\top$, klasycznym estymatorem jest macierz kowariancji z próby:

$$\boxed{\widehat{\boldsymbol{W}_1} = \frac{1}{N-1} \sum_{t=1}^{N} (\boldsymbol{e}_t - \bar{\boldsymbol{e}})(\boldsymbol{e}_t - \bar{\boldsymbol{e}})^\top, \qquad \bar{\boldsymbol{e}} = \frac{1}{N} \sum_{t=1}^{N} \boldsymbol{e}_t.}$$

Dla prognoz wielokrokowych macierz błędów może zależeć od horyzontu. Często stosuje się uproszczenie

$$\boldsymbol{W}_h = k_h \boldsymbol{W}_1, \qquad k_h > 0,$$

ponieważ wspólny mnożnik skalarowy nie zmienia macierzy $\boldsymbol{G}_{MinT}$. W praktyce estymacja powinna opierać się na błędach/resztach uzyskanych bez wykorzystania obserwacji testowych. Kolumny macierzy reszt muszą odpowiadać dokładnie tej samej kolejności szeregów co kolumny macierzy prognoz bazowych. Dla obliczenia kowariancji należy również zadbać o porównywalny zakres czasowy i obsługę braków danych.

4.5.6.3 MinT z pełną kowariancją a MinT ze shrinkage Bezpośredni estymator kowariancji może być niestabilny, zwłaszcza gdy liczba szeregów n jest duża w stosunku do liczby obserwacji N. Jeżeli $n \geq N$, klasyczna macierz kowariancji z próby może być osobliwa, a jej odwracanie niemożliwe lub numerycznie niestabilne.

Rozwiązaniem jest **estymator shrinkage**, który przybliża macierz pełną macierzą diagonalną:

$$\widehat{\boldsymbol{W}}_{shrink} = (1-\lambda)\widehat{\boldsymbol{W}}_{sam} + \lambda\,\mathrm{diag}(\widehat{\boldsymbol{W}}_{sam}), \qquad 0 \leq \lambda \leq 1.$$

Współczynnik λ określa siłę kurczenia elementów pozadiagonalnych w kierunku zera. W praktycznych implementacjach jego wartość jest wyznaczana procedurą estymacji shrinkage, a nie musi być arbitralnie ustawiana przez użytkownika. Dzięki temu zachowane zostają oszacowania wariancji poszczególnych szeregów, a niepewne korelacje są stabilizowane.

Zalety MinT: uwzględnia zarówno wariancje, jak i współzależności błędów; ma interpretację optymalizacyjną; w ramach klasy liniowych, nieobciążonych metod uzgadniania minimalizuje sumę wariancji błędów prognoz uzgodnionych przy przyjętych założeniach; wykorzystuje informację z wielu poziomów hierarchii.

Wady MinT: wymaga oszacowania macierzy kowariancji; jakość zależy od reprezentatywności reszt i stabilności estymatora; pełna macierz jest kosztowna obliczeniowo i może być osobliwa w wymiarze wysokim; założenie nieobciążoności prognoz bazowych nie zawsze jest spełnione.

Zastosowanie w projekcie. MinT jest jedną z najważniejszych metod uzgadniania, którą należy porównać z OLS, WLS i BU. W szczególności warto zestawić wariant `mint_cov` z `mint_shrink`, ponieważ liczba szeregów w hierarchii może być duża względem liczby dostępnych punktów czasowych. Nie należy jednak z góry zakładać, że MinT zawsze wygra empirycznie – wynik zależy od jakości estymacji macierzy kowariancji, modelu bazowego oraz struktury badanych danych.

4.5.7 Relacja pomiędzy OLS, WLS i MinT

Wspólny wzór pozwala zrozumieć warianty jako różne założenia dotyczące $\boldsymbol{W}_h$:

Metoda	Przyjęta macierz wag / kowariancji	Uwzględniane informacje
OLS	$\boldsymbol{W}_h = \boldsymbol{I}$	jednakowa wariancja, brak korelacji
WLS-var	$\boldsymbol{W}_h = \mathrm{diag}(\hat{\sigma}_i^2)$	różne wariancje, brak korelacji
WLS-struct	$\boldsymbol{W}_h = \mathrm{diag}(\boldsymbol{S}\boldsymbol{1})$	liczba szeregów składowych
MinT-cov	pełna $\widehat{\boldsymbol{W}}_h$	wariancje i kowariancje z próby
MinT-shrink	skurczona $\widehat{\boldsymbol{W}}_h$	wariancje i stabilizowane kowariancje

OLS i WLS są prostszymi specyfikacjami macierzy wag w rodzinie metod uzgadniania. MinT wykorzystuje pełną informację o współzależnościach błędów, o ile można ją wiarygodnie oszacować. W dokumentacji `fabletools` warianty są dostępne w ramach funkcji `min_trace()` pod nazwami `"ols"`, `"wls_var"`, `"wls_struct"`, `"mint_cov"` i `"mint_shrink"`.

4.5.8 Implementacja metod hierarchicznych w R

4.5.8.1 Pakiet `fable` / `fabletools` Pakiet `fable` służy do dopasowywania modeli prognozujących, natomiast `fabletools` dostarcza m.in. narzędzia do agregacji i uzgadniania prognoz. W praktyce strukturę danych można zbudować z użyciem `aggregate_key()`, a następnie dopasować modele do wszystkich szeregów w hierarchii i przekazać je do `reconcile()`.

```
library(dplyr)
library(tsibble)
library(fable)
library(fabletools)

# Przykładowy schemat dla hierarchii region / sklep.
# Zmienna sprzedaz jest agregowana przez sumowanie.
dane_h <- dane |>
  aggregate_key(region / sklep, sprzedaz = sum(sprzedaz))

modele_h <- dane_h |>
  model(
    ets    = ETS(sprzedaz),
    arima  = ARIMA(sprzedaz),
    snaive = SNAIVE(sprzedaz)
  )

# Przykładowe metody uzgadniania dla modelu ETS.
modele_uzgodnione <- modele_h |>
  reconcile(
    bu          = bottom_up(ets),
    td_avg      = top_down(ets, method = "average_proportions"),
    td_sum      = top_down(ets, method = "proportion_averages"),
    td_forecast = top_down(ets, method = "forecast_proportions"),
    mo          = middle_out(ets, split = 1),
    ols         = min_trace(ets, method = "ols"),
    wls_var     = min_trace(ets, method = "wls_var"),
    mint_shrink = min_trace(ets, method = "mint_shrink")
  )

prognozy_h <- modele_uzgodnione |> forecast(h = 12)
```

W powyższym przykładzie `split` wskazuje poziom wybrany dla Middle-Out i należy go dopasować do rzeczywistej struktury hierarchii. Przed użyciem trzeba również upewnić się, że obserwacje są poprawnie zagregowane oraz że wszystkie szeregi mają zgodny indeks czasu.

4.5.8.2 Pakiet `hts` Pakiet `hts` udostępnia klasyczne narzędzia do tworzenia i prognozowania hierarchicznych oraz grupowych szeregów czasowych. Dla obiektu klasy `hts` można użyć metody `forecast()` z parametrami `method` i `fmethod`. W dokumentacji występują m.in.

następujące warianty:

- `method = "bu"` – Bottom-Up,
- `method = "tdgsa"` – Top-Down, średnie udziały historyczne,
- `method = "tdgsf"` – Top-Down, proporcje średnich historycznych,
- `method = "tdfp"` – Top-Down, udziały prognozowe,
- `method = "mo"` – Middle-Out,
- `method = "comb"` – optymalna kombinacja prognoz.

Dla `method = "comb"` parametr `weights` pozwala wybrać m.in. `"ols"`, `"wls"`, `"mint"` lub `"nseries"`; parametr `covariance` przy MinT umożliwia użycie estymatora shrinkage (`"shr"`) albo kowariancji z próby (`"sam"`).

```
library(hts)
library(forecast)

# bottom_matrix: macierz szeregów najniższego poziomu,
# każdy szereg w osobnej kolumnie.
# Przykładowa struktura: 2 węzły na poziomie pierwszym,
# a następnie odpowiednio 3 i 2 węzły na poziomie dolnym.
y_hts <- hts::hts(bottom_matrix, nodes = list(2, c(3, 2)))

fc_bu <- forecast(y_hts, h = 12, method = "bu", fmethod = "arima")
fc_td <- forecast(y_hts, h = 12, method = "tdgsa", fmethod = "ets")
fc_ols <- forecast(y_hts, h = 12, method = "comb", weights = "ols")
fc_wls <- forecast(y_hts, h = 12, method = "comb", weights = "wls")
fc_mint <- forecast(
  y_hts, h = 12,
  method = "comb", weights = "mint", covariance = "shr"
)
```

Wybór biblioteki powinien zależeć od formatu danych i potrzeb eksperymentu. `hts` jest użyteczny w klasycznym workflow opartym na obiektach `ts` i macierzach, natomiast `fable`/`fabletools` wpisuje się w workflow `tsibble`/`dplyr` i oferuje deklaratywny sposób definiowania modeli oraz uzgadniania.

5 Miary dokładności prognoz

5.1 Definicje ogólne i oznaczenia

Niech y_{T+h} oznacza wartość rzeczywistą, a $\hat{y}_{T+h|T}$ – prognozę wyznaczoną w chwili T na horyzont h. Błąd prognozy definiujemy jako

$$e_{T+h} = y_{T+h} - \hat{y}_{T+h|T}.$$

Dla zbioru testowego zawierającego H obserwacji miary dokładności wyznaczane są na

podstawie wektora błędów $\boldsymbol{e} = (e_{T+1}, \ldots, e_{T+H})$. Im mniejsza wartość większości poniższych miar, tym dokładniejsza prognoza. Wyjątkiem są miary kierunkowe lub diagnostyczne, dla których interpretacja zależy od znaku albo punktu odniesienia.

W hierarchii każdą miarę należy najpierw obliczać dla poszczególnych szeregów i poziomów. Dopiero potem należy zdecydować, jak wyniki agregować (np. średnia nieważona, średnia ważona znaczeniem biznesowym, wynik oddzielnie dla każdego poziomu). Nie należy bez uzasadnienia sumować surowych błędów MAE lub RMSE z szeregów o bardzo różnych skalach.

5.2 MAE – Mean Absolute Error

Średni błąd bezwzględny jest średnią arytmetyczną wartości bezwzględnych błędów prognozy:

$$\boxed{MAE = \frac{1}{H} \sum_{h=1}^{H} \left| y_{T+h} - \hat{y}_{T+h|T} \right|.}$$

Sposób obliczenia: obliczyć błąd dla każdej obserwacji testowej; usunąć znak przez wartość bezwzględną; zsumować błędy bezwzględne; podzielić wynik przez liczbę prognoz.

MAE jest wyrażony w jednostkach oryginalnej zmiennej. Minimalizacja oczekiwanej straty bezwzględnej prowadzi do prognozy odpowiadającej medianie warunkowego rozkładu przyszłej wartości.

Zalety: łatwa interpretacja; odporność na pojedyncze duże błędy większa niż w RMSE; symetryczne traktowanie dodatnich i ujemnych odchyleń.

Wady: zależy od skali szeregu; nie jest bezpośrednio porównywalny pomiędzy szeregami o różnych jednostkach lub poziomach; nie rozróżnia umiarkowanych i bardzo dużych błędów tak silnie jak RMSE.

Zastosowanie w projekcie. MAE jest podstawową miarą błędu bezwzględnego. Będzie przydatna do oceny jakości prognoz w ramach jednego szeregu oraz do porównania metod dla szeregów o podobnej skali. W zbiorze wieloszeregów warto raportować MAE per poziom hierarchii.

5.3 MAPE – Mean Absolute Percentage Error

Średni bezwzględny błąd procentowy wyraża błąd prognozy jako procent wartości rzeczywistej:

$$\boxed{MAPE = \frac{100\%}{H} \sum_{h=1}^{H} \left| \frac{y_{T+h} - \hat{y}_{T+h|T}}{y_{T+h}} \right|.}$$

Sposób obliczenia: dla każdej obserwacji testowej podzielić wartość bezwzględną błędu przez wartość bezwzględną wartości rzeczywistej, obliczyć średnią z otrzymanych ilorazów i pomnożyć przez 100%.

Zalety: interpretacja procentowa; brak jednostki; może ułatwiać porównanie szeregów o różnych skalach, jeżeli wartości rzeczywiste są odpowiednio oddalone od zera i dodatnie.

Wady i ograniczenia: dla $y_{T+h} = 0$ miara jest niezdefiniowana; dla wartości bliskich zeru może przyjmować bardzo duże wartości; dla danych ujemnych jej klasyczna interpretacja procentowa staje się problematyczna; może silnie karać prognozy w okresach niskich wartości. W praktyce pomijanie zer lub zastępowanie ich arbitralną stałą zmienia definicję miary i może zniekształcać porównanie.

Zastosowanie w projekcie. MAPE można raportować jako miarę pomocniczą, jeżeli badana zmienna przyjmuje wartości dodatnie i niezerowe. Dla danych sprzedażowych o częstych zerach nie powinna być główną miarą oceny.

5.4 MASE – Mean Absolute Scaled Error

MASE zaproponowano jako skalowaną miarę błędu, która umożliwia porównanie prognoz dla szeregów o różnych skalach. W mianowniku wykorzystuje się średni błąd bezwzględny prognoz naiwnych obliczony na zbiorze treningowym.

Dla szeregu bez sezonowości, przy T obserwacjach treningowych:

$$Q_{naive} = \frac{1}{T-1} \sum_{t=2}^{T} |y_t - y_{t-1}|.$$

MASE na zbiorze testowym wynosi

$$\boxed{MASE = \frac{\frac{1}{H} \sum_{h=1}^{H} |y_{T+h} - \hat{y}_{T+h|T}|}{\frac{1}{T-1} \sum_{t=2}^{T} |y_t - y_{t-1}|}.}$$

Dla szeregu sezonowego długości m mianownik należy oprzeć na błędach naiwnej prognozy sezonowej:

$$Q_{snaive} = \frac{1}{T-m} \sum_{t=m+1}^{T} |y_t - y_{t-m}|,$$

$$\boxed{MASE_{sez} = \frac{\frac{1}{H} \sum_{h=1}^{H} |y_{T+h} - \hat{y}_{T+h|T}|}{\frac{1}{T-m} \sum_{t=m+1}^{T} |y_t - y_{t-m}|}.}$$

Interpretacja. Wartość $MASE < 1$ oznacza, że średni błąd bezwzględny ocenianej prognozy na zbiorze testowym jest mniejszy niż skala błędu jednokrokowej prognozy naiwnej (lub sezonowej naiwnej) obliczonej na zbiorze treningowym. Wartość $MASE > 1$ oznacza przekroczenie tej skali. Nie jest to dokładnie to samo, co porównanie naiwnej i badanej prognozy na identycznym zbiorze testowym – mianownik MASE wyznacza się na danych treningowych.

Zalety: niezależność od skali szeregu; możliwość porównywania wielu szeregów; w odróżnieniu od MAPE nie dzieli przez pojedynczą wartość rzeczywistą; naturalne odniesienie do modelu naiwnego.

Wady: miara jest niezdefiniowana, jeżeli mianownik wynosi zero (np. szereg stały w całym zbiorze treningowym); wymaga zachowania właściwego zbioru treningowego przy obliczeniach; wynik zależy od wyboru wersji niesezonowej lub sezonowej.

Zastosowanie w projekcie. MASE jest jedną z rekomendowanych miar podstawowych do porównywania dokładności pomiędzy węzłami o różnych poziomach i skalach. Należy wyraźnie określić długość sezonu m oraz obliczać mianownik wyłącznie na danych treningowych w danym podziale walidacyjnym.

5.5 RMSE – Root Mean Squared Error

Pierwiastek błędu średniokwadratowego jest zdefiniowany jako

$$\boxed{RMSE = \sqrt{\frac{1}{H}\sum_{h=1}^{H}\left(y_{T+h} - \hat{y}_{T+h|T}\right)^2}.}$$

Sposób obliczenia: podnieść każdy błąd do kwadratu; obliczyć średnią kwadratów; wyciągnąć pierwiastek kwadratowy.

RMSE jest wyrażony w jednostkach oryginalnego szeregu. W przeciwieństwie do MAE mocniej karze duże błędy, ponieważ ich wkład do sumy rośnie kwadratowo. Minimalizacja oczekiwanej straty kwadratowej jest powiązana z prognozą warunkowej średniej.

Zalety: uwypukla duże błędy; jest standardową i szeroko stosowaną miarą; ma bezpośredni związek z wariancją błędu; dobrze sprawdza się, gdy bardzo duże pomyłki są szczególnie kosztowne.

Wady: jest wrażliwy na obserwacje odstające; zależy od skali szeregu; może być zdominowany przez pojedyncze epizody o bardzo dużym błędzie.

Zastosowanie w projekcie. RMSE powinien być raportowany razem z MAE, aby rozróżnić modele o niewielkich typowych błędach od modeli, które sporadycznie generują duże pomyłki. Szczególnie przydatne będzie porównanie RMSE pomiędzy BASE, BU, OLS/WLS i MinT dla tych samych węzłów i horyzontów.

5.6 RRMSE – Relative Root Mean Squared Error

W projekcie względny RMSE definiujemy jako iloraz RMSE ocenianego modelu i RMSE modelu referencyjnego, obliczonych dla tego samego szeregu, tego samego zbioru testowego i identycznego horyzontu:

$$\boxed{RRMSE = \frac{RMSE_{model}}{RMSE_{ref}}.}$$

Czasami wynik podaje się w procentach:

$$RRMSE_{\%} = 100\% \cdot \frac{RMSE_{model}}{RMSE_{ref}}.$$

W projekcie naturalnym modelem referencyjnym będzie Naive albo Seasonal Naive – wybór należy dostosować do sezonowości szeregu. Dla $RRMSE < 1$ model badany osiąga mniejszy RMSE niż benchmark; dla $RRMSE = 1$ wyniki są równe; dla $RRMSE > 1$ model badany wypada gorzej.

Sposób obliczenia: obliczyć RMSE ocenianego modelu; obliczyć RMSE benchmarku na tych samych obserwacjach; podzielić pierwszą wartość przez drugą. Jeżeli $RMSE_{ref} = 0$, RRMSE jest niezdefiniowany.

Zalety: bezwymiarowość; czytelna interpretacja względem modelu referencyjnego; możliwość porównywania względnej poprawy pomiędzy szeregami o różnych skalach.

Wady: zależy od wyboru benchmarku; jest niestabilny, gdy RMSE modelu referencyjnego jest bliski zeru; nie ma jednej uniwersalnej konwencji obliczania RRMSE, dlatego definicję trzeba jawnie podać w pracy.

Zastosowanie w projekcie. RRMSE może być przydatny do prezentacji względnej korzyści z uzgadniania. Przykładowo można obliczyć stosunek RMSE metody MinT do RMSE prognoz BASE dla każdego węzła, a dodatkowo porównać MinT z prognozą Naive/SNaive. Benchmark musi być ten sam dla wszystkich metod w danym zestawieniu.

5.7 RMSSE i WRMSSE – miary uzupełniające dla danych hierarchicznych

5.7.1 RMSSE – Root Mean Squared Scaled Error

W pracy dotyczącej konkursu M5 zastosowano pierwiastek średniego kwadratowego błędu skalowanego. Dla szeregu bez sezonowości:

$$RMSSE_i = \sqrt{\frac{\frac{1}{H}\sum_{h=1}^{H}(y_{i,T+h} - \hat{y}_{i,T+h|T})^2}{\frac{1}{T-1}\sum_{t=2}^{T}(y_{i,t} - y_{i,t-1})^2}}.$$

W wersji sezonowej mianownik można oprzeć na sezonowych różnicach $y_{i,t} - y_{i,t-m}$. RMSSE jest analogiczną do MASE miarą skalowaną, ale bazuje na kwadratach błędów i dlatego silniej karze duże pomyłki. W przeciwieństwie do MAPE nie wymaga dzielenia przez pojedynczą wartość rzeczywistą, co jest istotne w szeregach z zerami i popytem sporadycznym.

5.7.2 WRMSSE – Weighted Root Mean Squared Scaled Error

Dla zbioru n szeregów ważona miara WRMSSE jest średnią ważoną miar RMSSE:

$$WRMSSE = \sum_{i=1}^{n} w_i RMSSE_i, \qquad w_i \geq 0, \qquad \sum_{i=1}^{n} w_i = 1.$$

Wagi w_i powinny odzwierciedlać znaczenie szeregów dla analizowanego zastosowania. Mogą być ustalone na podstawie udziału w przychodach, wolumenu sprzedaży, kosztu błędnej decyzji lub innych, merytorycznie uzasadnionych kryteriów. W konkursie M5 wagi oparto na skumulowanej wartości sprzedaży (dolarowej) z ostatnich 28 dni zbioru treningowego, tj. sumie iloczynów liczby sprzedanych jednostek i ceny. M5 obejmował 42 840 szeregów w 12 przekrojowych poziomach agregacji, a do oceny wykorzystano wariant RMSSE odporniejszy na problem zerowych wartości rzeczywistych niż MAPE.

Zalety: RMSSE jest bezwymiarowy i silniej karze duże pomyłki; WRMSSE pozwala uwzględnić znaczenie biznesowe poszczególnych szeregów; rozwiązanie jest szczególnie użyteczne dla danych sprzedażowych i popytu przerywanego.

Wady: wynik WRMSSE zależy od przyjętego systemu wag; źle dobrane wagi mogą nadmiernie uprzywilejować największe szeregi; skalowanie jest nieokreślone, gdy wszystkie różnice w mianowniku są zerowe.

Zastosowanie w projekcie. RMSSE warto dodać do zestawu miar obok MAE, MAPE, MASE i RMSE. WRMSSE będzie szczególnie uzasadniony, jeżeli szeregi mają różne znaczenie biznesowe lub projekt obejmuje dane o charakterze sprzedażowym. Przy innych danych należy zdefiniować wagi zgodnie z celem badania, a nie kopiować bezrefleksyjnie system wag M5.

5.8 Zestawienie miar

Miara	Jednostka	Reakcja na duże błędy	Problem z zerami w danych rzeczywistych	Główna rola
MAE	jednostka zmiennej	umiarkowana	brak szczególnego problemu	typowy błąd bezwzględny
MAPE	procent	zależna od wartości rzeczywistej	tak, miara niezdefiniowana	względny błąd procentowy przy danych dodatnich
MASE	bezwymiarowa	umiarkowana	nie, ale mianownik może być zerowy	porównanie różnych skal i benchmark naiwny
RMSE	jednostka zmiennej	wysoka	brak szczególnego problemu	kara za duże pomyłki
RRMSE	bezwymiarowa	wysoka	zależy od RMSE benchmarku	względne porównanie z modelem referencyjnym
RMSSE	bezwymiarowa	wysoka	nie, ale mianownik może być zerowy	skalowany błąd kwadratowy
WRMSSE	bezwymiarowa	wysoka	nie, ale mianownik może być zerowy	ważona ocena wielu szeregów

6 Ocena prognoz w strukturze hierarchicznej

6.1 Porównywanie jakości pomiędzy poziomami

W hierarchii wartości agregatów są zazwyczaj znacznie większe niż wartości szeregów najniższego poziomu. Z tego względu bezpośrednie porównanie MAE lub RMSE pomiędzy poziomami może być mylące. Wskazane jest raportowanie:

1. miar osobno dla każdego szeregu,
2. średnich miar w obrębie każdego poziomu hierarchii,
3. miar ważonych, jeżeli poziomy lub szeregi mają różne znaczenie praktyczne.

Można zastosować średnią nieważoną po szeregach (*macro-average*):

$$MAE_{macro} = \frac{1}{n}\sum_{i=1}^{n} MAE_i,$$

lub średnią ważoną:

$$MAE_{weighted} = \sum_{i=1}^{n} w_i MAE_i, \qquad \sum_{i=1}^{n} w_i = 1.$$

Analogiczne agregacje można zdefiniować dla MASE, RMSSE i innych miar. Należy jednak jasno opisać, czy wagi są jednakowe dla wszystkich węzłów, czy też odzwierciedlają znaczenie biznesowe. W strukturze, w której agregaty i liście zawierają nakładającą się informację, sumowanie wyników ze wszystkich węzłów może dodatkowo wielokrotnie uwzględniać te same obserwacje. Warto więc przedstawić wyniki oddzielnie dla poziomów, a jedną liczbę zbiorczą traktować jako dodatkowe podsumowanie.

6.2 Kontrola spójności jako odrębna diagnostyka

Spójność jest własnością algebraiczną, a nie miarą dokładności. Dla prognozy uzgodnionej można sprawdzić resztę ograniczeń. Jeżeli $\boldsymbol{C}\boldsymbol{y} = \boldsymbol{0}$ opisuje zależności agregacyjne, to diagnostyka spójności może mieć postać

$$\boxed{D_{coh} = \|\boldsymbol{C}\widetilde{\boldsymbol{y}}\|_2}$$

lub

$$D_{coh,\infty} = \|\boldsymbol{C}\widetilde{\boldsymbol{y}}\|_\infty.$$

Dla prognoz spójnych wartości te powinny być równe zeru z dokładnością do błędów numerycznych. Diagnostykę można też zastosować do prognoz BASE, aby zmierzyć skalę niespójności przed uzgadnianiem. Nie należy jednak interpretować małego D_{coh} jako dowodu małego błędu prognozy względem wartości rzeczywistej.

6.3 Podział treningowy, testowy i walidacja krocząca

Ocena jakości musi respektować chronologię danych. Losowe mieszanie obserwacji treningowych i testowych prowadzi do wycieku informacji z przyszłości. Podstawowa procedura polega na:

1. ustaleniu momentu odcięcia T,
2. dopasowaniu modelu oraz estymacji udziałów/kowariancji wyłącznie na danych nie późniejszych niż T,
3. wygenerowaniu prognoz na horyzont H,
4. porównaniu prognoz z obserwacjami rzeczywistymi po chwili T.

Bardziej wiarygodnym rozwiązaniem jest walidacja krocząca (*rolling forecast origin*). Dla kolejnych momentów odcięcia $T_1 < T_2 < \cdots < T_R$ wyznacza się prognozy i błędy, a następnie agreguje wyniki:

$$MAE_{CV} = \frac{1}{RH} \sum_{r=1}^{R} \sum_{h=1}^{H} |y_{T_r+h} - \hat{y}_{T_r+h|T_r}|.$$

Analogicznie wyznacza się pozostałe miary. Przy każdej iteracji walidacji wszystkie elementy procedury – w tym estymację parametrów ETS/ARIMA, udziałów Top-Down oraz macierzy $\boldsymbol{W}_h$ dla MinT – należy wykonać wyłącznie na danych dostępnych do danego momentu odcięcia. W przeciwnym razie wyniki będą obciążone informacją z przyszłości.

7 Rekomendowany schemat eksperymentu

Dla zachowania porównywalności metod proponuje się następujący plan:

1. **Przygotowanie hierarchii.** Zdefiniować poziomy, kolejność szeregów oraz macierz sumowania $\boldsymbol{S}$. Zweryfikować, czy agregaty historyczne są dokładnie sumą szeregów składowych.
2. **Eksploracja.** Sprawdzić braki danych, wartości odstające, zera, sezonowość, trend, możliwe zmiany strukturalne i liczbę obserwacji w każdym szeregu.
3. **Modele bazowe.** Dopasować Naive, SNaive, ETS i ARIMA. Modele mogą różnić się pomiędzy węzłami, ale horyzont prognozy musi być wspólny.
4. **Prognozy BASE.** Zachować niezależne prognozy ze wszystkich węzłów jako benchmark bez uzgadniania.
5. **Metody proste.** Wyznaczyć BU, TD (co najmniej dwa warianty udziałów) oraz – jeżeli struktura na to pozwala – MO.
6. **Metody macierzowe.** Wyznaczyć OLS, WLS-var oraz MinT z pełną i skurczoną macierzą kowariancji; w razie potrzeby dodać WLS-struct.
7. **Ocena.** Dla wszystkich metod użyć tych samych okresów testowych i tych samych horyzontów. Raportować MAE, RMSE, MASE, MAPE (tylko gdy właściwe), RRMSE oraz – jeśli uzasadnione – RMSSE/WRMSSE.
8. **Kontrola.** Zweryfikować spójność prognoz po uzgadnianiu oraz diagnostykę reszt modeli bazowych.
9. **Wybór rozwiązania.** Nie opierać decyzji wyłącznie na jednej liczbie. Uwzględnić dokładność na ważnych poziomach, stabilność wyników w walidacji kroczącej, wymagania interpretacyjne i koszt obliczeniowy.

W tabelach wynikowych należy zachować rozdział pomiędzy rodzajem modelu bazowego a metodą uzgadniania. Przykładowo kombinacja `ETS + MinT-shrink` oznacza, że prognozy bazowe wygenerowano modelem ETS, a następnie uzgodniono metodą MinT z estymatorem shrinkage. Analogicznie można rozpatrzyć `ARIMA + Bottom-Up` czy `SNaive + OLS`.

8 Najważniejsze uwagi metodologiczne i ograniczenia

- **Spójność nie gwarantuje dokładności.** Uzgadnianie wymusza relacje agregacyjne, ale nie zapewnia automatycznie niższego błędu w każdym węźle.

- **Wynik MinT zależy od estymacji kowariancji.** Wysoki wymiar hierarchii przy krótkiej historii przemawia za shrinkage lub prostszymi wariantami OLS/WLS.
- **Top-Down nie jest metodą uniwersalną dla wszystkich struktur.** Klasyczne udziały wymagają interpretowalnego drzewa i poprawnych mianowników.
- **Prognozy ujemne.** Linearne metody uzgadniania mogą wytworzyć ujemne wartości nawet wtedy, gdy zmienna jest nieujemna. Jeżeli nieujemność jest warunkiem merytorycznym, należy rozważyć uzgadnianie z ograniczeniami. Jest to wówczas zadanie optymalizacyjne z dodatkowymi ograniczeniami, a nie dokładnie ta sama prosta projekcja liniowa.
- **Zmienna agregowana.** Wszystkie zaprezentowane klasyczne wzory zakładają addytywność. Dla wskaźników, średnich, udziałów i ilorazów potrzebna jest inna specyfikacja ograniczeń lub odpowiednia transformacja.
- **Wyciek danych.** Reszty użyte do estymacji $\boldsymbol{W}_h$, proporcje historyczne i parametry modeli muszą pochodzić wyłącznie z części treningowej danego podziału walidacyjnego.
- **Porównywalność.** Wszystkie metody należy porównywać na tych samych okresach, przy tym samym horyzoncie oraz na tych samych szeregach.

9 Literatura i dokumentacja

Poniższe źródła stanowią podstawę teoretyczną i implementacyjną rozdziału. Link podany w czwartym punkcie prowadzi do pracy dotyczącej konkursu M5, a nie do publikacji o algorytmie MinT; wykorzystano ją w części o RMSSE i WRMSSE.

1. Hyndman, R. J., Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*, 2nd ed., rozdział 10: Forecasting hierarchical or grouped time series. OTexts. https://otexts.com/fpp2/hierarchical-forecasting.html
2. Hyndman, R. J., Ahmed, R. A., Athanasopoulos, G., Shang, H. L. (2011). Optimal combination forecasts for hierarchical time series. *Computational Statistics & Data Analysis*, 55(9), 2579–2589. DOI: https://doi.org/10.1016/j.csda.2011.03.006. https://robjhyndman.com/publications/hierarchical/
3. Wickramasuriya, S. L., Athanasopoulos, G., Hyndman, R. J. (2019). Optimal forecast reconciliation for hierarchical and grouped time series through trace minimization. *Journal of the American Statistical Association*, 114(526), 804–819. DOI: https://doi.org/10.1080/01621459.2018.1448825. https://robjhyndman.com/publications/mint/
4. Makridakis, S., Spiliotis, E., Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364. DOI: https://doi.org/10.1016/j.ijforecast.2021.11.013. https://www.sciencedirect.com/science/article/pii/S0169207021001874
5. Hyndman, R. J., Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688.
6. Dokumentacja pakietu `forecast`, w szczególności funkcje `ets()`, `auto.arima()`, `naive()`, `snaive()` oraz `accuracy()`: https://pkg.robjhyndman.com/forecast/.
7. Dokumentacja pakietu `hts` – prognozowanie szeregów hierarchicznych i grupowych, w tym `forecast.gts()`, `combinef()` i `MinT()`: https://cran.r-project.org/package=hts.
8. Dokumentacja pakietu `fable` i `fabletools`, w szczególności `ETS()`, `ARIMA()`, `NAIVE()`,

`SNAIVE()`, `reconcile()` i `min_trace()`: https://fable.tidyverts.org/ oraz https://fable.tidyverts.org/reference/.