Prognozowanie Hierarchicznych Szeregów Czasowych

2026-11-11

Spis treści

1 Cel i sposób korzystania z opracowania **1**

2 Podstawy prognozowania hierarchicznego **2**
2.1 Hierarchia i macierz sumowania 2
2.2 Spójność prognoz 2

3 Modele prognoz bazowych **3**
3.1 Naive i Seasonal Naive 3
3.2 ETS - wygładzanie wykładnicze 3
3.3 ARIMA i SARIMA 4

4 Metody uzgadniania prognoz **5**
4.1 BASE - brak uzgadniania 5
4.2 Bottom-Up (BU) 5
4.3 Top-Down (TD) 5
4.4 Middle-Out (MO) 6
4.5 OLS, WLS i MinT - wspólny zapis macierzowy 6
4.6 Implementacja w R: `fable` i `hts` 7

5 Miary dokładności prognoz **8**
5.1 MAE - Mean Absolute Error 9
5.2 MAPE - Mean Absolute Percentage Error 9
5.3 MASE - Mean Absolute Scaled Error 9
5.4 RMSE - Root Mean Squared Error 9
5.5 RMSSE - Root Mean Squared Scaled Error 10
5.6 WRMSSE - Weighted RMSSE 10
5.7 Zestawienie miar i przykładowe obliczenia w R 10

6 Ocena wyników w hierarchii **11**
6.1 Porównywanie poziomów i kontrola spójności 11
6.2 Walidacja krocząca i unikanie wycieku danych 11

7 Najważniejsze ograniczenia **12**

1 Cel i sposób korzystania z opracowania

Ten dokument jest krótkim przewodnikiem do tematu **„Prognozowanie Hierarchicznych Szeregów Czasowych”**. Wyjaśnia, jak powstają prognozy pojedynczych szeregów, dlaczego prognozy w hierarchii mogą być niespójne, jak je uzgadniać oraz jak rzetelnie oceniać ich jakość. Mapomóc zrozumieć metody wykorzystywane w projekcie i świadomie interpretować wyniki.

Proces składa się z dwóch odrębnych etapów:

1. **Prognozowanie bazowe** (*base forecasting*) - model, np. ETS lub ARIMA, wyznacza prognozę każdego szeregu.
2. **Uzgadnianie prognoz** (*forecast reconciliation*) - prognozy są korygowane tak, aby zachować relacje agregacyjne między poziomami.

Model bazowy opisuje dynamikę szeregu, a metoda uzgadniania określa, jak łączyć informacje z różnych poziomów hierarchii. Przykładowo zapis **ETS + MinT-shrink** oznacza: prognozy bazowe otrzymano modelem ETS, a następnie uzgodniono je metodą MinT z estymatorem shrinkage.

2 Podstawy prognozowania hierarchicznego

2.1 Hierarchia i macierz sumowania

Rozważmy n szeregów, z których m należy do najniższego poziomu (*bottom level*). Wektor wszystkich obserwacji w chwili t oznaczmy przez $\boldsymbol{y}_t$, a wektor obserwacji z najniższego poziomu przez $\boldsymbol{b}_t$. W przypadku addytywnym, gdy agregat jest sumą swoich składników, zachodzi

$$\boldsymbol{y}_t = \boldsymbol{S}\boldsymbol{b}_t,$$

gdzie $\boldsymbol{S}$ jest macierzą sumowania (*summing matrix*) o wymiarach $n \times m$. Jej wiersze określają, które szeregi dolnego poziomu składają się na dany węzeł. Wiersze odpowiadające szeregom najniższego poziomu tworzą macierz jednostkową.

Przykładowo dla sumy całkowitej T, regionów A i B oraz produktów A_1, A_2, B_1, B_2 można przyjąć kolejność węzłów $(T, A, B, A_1, A_2, B_1, B_2)$. Wówczas

$$\boldsymbol{S} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \qquad \boldsymbol{y}_t = \boldsymbol{S}\boldsymbol{b}_t.$$

Macierz $\boldsymbol{S}$ jest wspólnym zapisem struktury hierarchii. Pozwala wyprowadzać agregaty z danych dolnego poziomu, opisywać warunki spójności oraz wyznaczać prognozy uzgodnione.

2.2 Spójność prognoz

Prognozy bazowe obliczane niezależnie dla każdego węzła nie muszą spełniać zależności agregacyjnych. Prognoza całkowita może być na przykład inna niż suma prognoz regionów. Wektor prognoz $\widetilde{\boldsymbol{y}}_{T+h|T}$ jest **spójny** (*coherent*), jeżeli istnieje wektor prognoz dolnego poziomu $\widetilde{\boldsymbol{b}}_{T+h|T}$ taki, że

$$\widetilde{\boldsymbol{y}}_{T+h|T} = \boldsymbol{S}\widetilde{\boldsymbol{b}}_{T+h|T}.$$

Spójność jest warunkiem algebraicznym, a nie miarą dokładności. Prognoza może być spójna, ale daleka od wartości rzeczywistych. Z kolei prognozy bazowe mogą być dokładne dla poszczególnych węzłów, lecz wzajemnie niespójne. W projekcie trzeba zatem osobno oceniać **dokładność** i **spójność**.

W hierarchii każdy węzeł niższego poziomu należy do jednego węzła nadrzędnego. W szeregach grupowych te same dane mogą być agregowane według kilku przecinających się klasyfikacji, np.

regionu i kategorii produktu. Macierzowa reprezentacja pozostaje użyteczna w obu przypadkach, jednak klasyczne metody Top-Down i Middle-Out są najbardziej naturalne dla hierarchii drzewiastej.

3 Modele prognoz bazowych

Modele w tej części są dopasowywane do pojedynczych szeregów. W praktyce możemy dopasować ten sam typ modelu do wszystkich węzłów albo wybrać model osobno dla każdego szeregu. Wybór powinien wynikać z charakteru danych i walidacji, a nie wyłącznie z dopasowania do próby uczącej.

3.1 Naive i Seasonal Naive

Naive zakłada, że przyszła wartość będzie równa ostatniej obserwacji. Jest odpowiednikiem modelu błądzenia losowego:

$$y_t = y_{t-1} + \varepsilon_t, \qquad \hat{y}_{T+h|T} = y_T.$$

Jest to prosty benchmark dla szeregu bez wyraźnego trendu i sezonowości. Nie estymuje parametrów, jest szybki i trudny do przeuczenia, ale nie reaguje na zmianę poziomu ani sezonowość.

Seasonal Naive (SNaive) powtarza ostatni zaobserwowany cykl sezonowy. Dla długości sezonu m prognoza ma postać

$$\hat{y}_{T+h|T} = y_{T+h-m\lceil h/m \rceil}.$$

Przykładowo dla danych miesięcznych z sezonowością roczną $m = 12$. SNaive jest naturalnym benchmarkiem dla danych sezonowych, lecz zakłada, że profil sezonowy pozostaje stabilny. Oba modele są ważnymi punktami odniesienia przy ocenie bardziej złożonych metod.

R w praktyce: `forecast::naive()` i `forecast::snaive()` w pakiecie `forecast`; `NAIVE()` i `SNAIVE()` w pakiecie `fable`.

```
library(forecast)
fc_naive  <- forecast::naive(y, h = 12)
fc_snaive <- forecast::snaive(y, h = 12)
```

3.2 ETS - wygładzanie wykładnicze

ETS (*Error, Trend, Seasonal*) to rodzina modeli przestrzeni stanów. Trzyliterowy zapis ETS(E, T, S) określa rodzaj błędu, trendu i sezonowości. Przykładowo `ETS(A,A,N)` oznacza błąd addytywny, trend addytywny i brak sezonowości. Wygładzanie wykładnicze przypisuje większą wagę nowszym obserwacjom.

Najprostszy model wygładzania prostego `ETS(A,N,N)` ma postać

$$\begin{aligned} y_t &= \ell_{t-1} + \varepsilon_t, \\ \ell_t &= \ell_{t-1} + \alpha\varepsilon_t = \alpha y_t + (1-\alpha)\ell_{t-1}, \end{aligned}$$

gdzie ℓ_t jest poziomem szeregu, a $\alpha \in (0, 1)$ - parametrem wygładzania. Im większe α, tym większy wpływ ostatniej obserwacji na aktualizację poziomu.

Dla modelu z trendem addytywnym `ETS(A,A,N)` stosuje się dodatkowo stan trendu b_t:

$$
\begin{aligned}
y_t &= \ell_{t-1} + b_{t-1} + \varepsilon_t, \\
\ell_t &= \ell_{t-1} + b_{t-1} + \alpha\varepsilon_t, \\
b_t &= b_{t-1} + \beta\varepsilon_t, \\
\hat{y}_{T+h|T} &= \ell_T + h b_T.
\end{aligned}
$$

W modelu sezonowym pojawia się składnik s_t. Dla addytywnego wariantu Holt-Wintersa (`ETS(A,A,A)`) równanie obserwacji jest postaci

$$
y_t = \ell_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t,
$$

a stany poziomu, trendu i sezonowości są aktualizowane odpowiednio parametrami α, β i γ. Sezonowość addytywna jest odpowiednia, gdy amplituda wahań jest w przybliżeniu stała. Wariant multiplikatywny może być przydatny, gdy amplituda rośnie wraz z poziomem, ale wymaga ostrożności przy zerach i wartościach ujemnych.

Parametry oraz stany początkowe estymuje się zwykle przez maksymalizację wiarygodności. Wybór wariantu może być wspierany kryterium AICc:

$$
AIC_c = -2\log L + 2k\frac{N}{N-k-1},
$$

gdzie L jest maksymalną wiarygodnością, k liczbą estymowanych parametrów, a N liczbą obserwacji. Niższa wartość AICc oznacza lepszy kompromis dopasowania i złożoności wśród porównywanych modeli. Nie gwarantuje jednak najmniejszego błędu na danych testowych.

Zalety: elastyczne modelowanie poziomu, trendu i sezonowości; czytelna interpretacja stanów; automatyczny dobór wariantu. **Ograniczenia:** brak bezpośrednich zmiennych objaśniających w klasycznej postaci; możliwe opóźnienie reakcji na nagłe zmiany; warianty multiplikatywne nie są odpowiednie dla danych z zerami lub wartościami ujemnymi.

R w praktyce: `forecast::ets()` i `fable::ETS()`. W `forecast::ets()` `model = "ZZZ"` pozwala automatycznie dobrać składniki, a `ic = "aicc"` wskazuje kryterium wyboru.

```
fit_ets <- forecast::ets(y, model = "ZZZ", ic = "aicc")
fc_ets  <- forecast::forecast(fit_ets, h = 12)
```

3.3 ARIMA i SARIMA

ARIMA(p,d,q) łączy autoregresję (AR), różnicowanie (I) i średnią ruchomą (MA). Operator opóźnień B definiuje się jako $By_t = y_{t-1}$. Model ma postać

$$
\phi(B)(1-B)^d y_t = c + \theta(B)\varepsilon_t,
$$

gdzie p jest rzędem części AR, d liczbą różnicowań, a q rzędem części MA. Wielomiany opóźnień to

$$
\phi(B) = 1 - \phi_1 B - \cdots - \phi_p B^p, \qquad \theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q.
$$

Różnicowanie ma doprowadzić do stacjonarności szeregu, czyli sytuacji, w której podstawowe własności probabilistyczne (np. średnia i wariancja) nie zmieniają się systematycznie w czasie. Dla sezonowości o okresie m stosuje się SARIMA:

$$\phi(B)\Phi(B^m)(1-B)^d(1-B^m)^D y_t = c + \theta(B)\Theta(B^m)\varepsilon_t.$$

Model zapisuje się jako ARIMA$(p,d,q)(P,D,Q)_m$. Parametry sezonowe opisują zależności oddalone o całe okresy sezonowe. Rzędy dobiera się przez analizę szeregu, testy różnicowania, kryteria informacyjne (np. AICc) i diagnostykę reszt. Reszty powinny być zbliżone do białego szumu; można sprawdzać ich wykres ACF i testem Ljunga-Boxa.

Zalety: elastyczne odwzorowanie autokorelacji i sezonowości; szeroka klasa modeli; możliwość włączenia regresorów zewnętrznych. **Ograniczenia:** konieczność właściwego różnicowania i doboru rzędów; trudniejsza interpretacja niż w prostych modelach ETS; wrażliwość na zmiany strukturalne i obserwacje nietypowe.

R w praktyce: `forecast::auto.arima()` oraz `fable::ARIMA()`. Wybór automatyczny należy zweryfikować diagnostyką reszt i walidacją kroczącą.

```
fit_arima <- forecast::auto.arima(y, seasonal = TRUE)
fc_arima  <- forecast::forecast(fit_arima, h = 12)
```

4 Metody uzgadniania prognoz

Niech $\widehat{\boldsymbol{y}}_{T+h|T}$ oznacza wektor prognoz bazowych dla wszystkich n węzłów. Metody uzgadniania przekształcają go w prognozy spójne. Przed wyborem metody warto pamiętać, że prostota niektórych rozwiązań może być zaletą: w małej próbie metoda o mniejszej liczbie estymowanych parametrów bywa stabilniejsza od bardziej złożonej.

4.1 BASE - brak uzgadniania

BASE oznacza pozostawienie prognoz bazowych bez korekty. Nie gwarantują one spójności, ale są niezbędnym punktem odniesienia: pozwalają ocenić, czy uzgadnianie poprawia jakość prognoz, a nie tylko wymusza zgodność sum.

4.2 Bottom-Up (BU)

Bottom-Up polega na prognozowaniu wszystkich szeregów najniższego poziomu, a następnie sumowaniu ich prognoz do poziomów wyższych. W zapisie macierzowym

$$\widetilde{\boldsymbol{b}}_{T+h|T} = \widehat{\boldsymbol{b}}_{T+h|T}, \qquad \widetilde{\boldsymbol{y}}_{T+h|T} = \boldsymbol{S}\widehat{\boldsymbol{b}}_{T+h|T}.$$

Metoda zawsze daje prognozy spójne. Jest prosta, nie wymaga estymacji udziałów ani macierzy kowariancji i dobrze zachowuje szczegółową informację z dolnego poziomu. Jej słabością jest pominięcie bezpośrednich informacji z poziomów agregacji: prognoza dolnego poziomu może być bardziej zmienna lub trudniejsza do oszacowania. BU jest dobrym wariantem bazowym, zwłaszcza gdy dostępne są długie i wiarygodne szeregi na poziomie szczegółowym.

4.3 Top-Down (TD)

Top-Down zaczyna od prognozy węzła nadrzędnego, a następnie rozdziela ją między węzły niższe przy użyciu udziałów p_j spełniających $\sum_j p_j = 1$. Dla węzła nadrzędnego a prognoza dziecka j ma postać

$$\widetilde{y}_{j,T+h|T} = p_j \widehat{y}_{a,T+h|T}.$$

Najczęściej spotyka się trzy sposoby wyznaczania udziałów:

- **Average proportions:** średnia z historycznych udziałów w każdym okresie, $p_j = T^{-1}\sum_t y_{j,t}/y_{a,t}$.
- **Proportion averages:** iloraz sum historycznych, $p_j = \sum_t y_{j,t}/\sum_t y_{a,t}$.
- **Forecast proportions:** udziały obliczone z prognoz bazowych, np. $p_{j,h} = \hat{y}_{j,T+h|T}/\sum_k \hat{y}_{k,T+h|T}$.

Pierwsze dwa warianty wykorzystują strukturę historyczną; trzeci - prognozowaną strukturę na dany horyzont. Metoda jest łatwa do wyjaśnienia biznesowo i może być skuteczna, gdy udziały są stabilne. Jej główne ograniczenie polega na utracie informacji o niezależnej dynamice szeregów niższych poziomów. Udziały trzeba ponadto wyznaczać ostrożnie, gdy wartości agregatu są zerowe lub bardzo małe. TD jest naturalna przede wszystkim dla hierarchii drzewiastej.

4.4 Middle-Out (MO)

Middle-Out łączy podejście Top-Down i Bottom-Up. Wybiera się poziom pośredni, prognozuje jego węzły, a następnie agreguje prognozy do góry (BU) i rozdziela je w dół (TD). Metoda może być użyteczna, gdy prognozy węzła głównego są zbyt ogólne, a prognozy najniższych poziomów zbyt niestabilne. Wynik zależy od wyboru poziomu podziału, dlatego wybór należy uzasadnić strukturą danych i walidacją.

4.5 OLS, WLS i MinT - wspólny zapis macierzowy

Metody optymalnej kombinacji można opisać przez liniowe uzgadnianie

$$\widetilde{\boldsymbol{y}}_{T+h|T} = \boldsymbol{S}\boldsymbol{G}\widehat{\boldsymbol{y}}_{T+h|T},$$

gdzie $\boldsymbol{G}$ przekształca prognozy wszystkich węzłów w prognozy dolnego poziomu. Warunek nieobciążoności i zachowania agregacji zapisuje się jako

$$\boldsymbol{S}\boldsymbol{G}\boldsymbol{S} = \boldsymbol{S}.$$

Niech $\boldsymbol{W}_h$ oznacza macierz kowariancji błędów prognoz bazowych dla horyzontu h. Uzgadnianie ważone można interpretować jako znalezienie wektora dolnego poziomu minimalizującego ważoną odległość od prognoz bazowych:

$$\min_{\boldsymbol{b}} (\widehat{\boldsymbol{y}} - \boldsymbol{S}\boldsymbol{b})^\top \boldsymbol{W}_h^{-1} (\widehat{\boldsymbol{y}} - \boldsymbol{S}\boldsymbol{b}).$$

Rozwiązanie prowadzi do postaci

$$\boxed{\widetilde{\boldsymbol{y}} = \boldsymbol{S}(\boldsymbol{S}^\top \boldsymbol{W}_h^{-1} \boldsymbol{S})^{-1} \boldsymbol{S}^\top \boldsymbol{W}_h^{-1} \widehat{\boldsymbol{y}}.}$$

Zapis ten pokazuje, że różnice między metodami wynikają przede wszystkim ze sposobu zdefiniowania $\boldsymbol{W}_h$:

Metoda	Przyjęta macierz $\boldsymbol{W}_h$	Założenie
OLS	$\boldsymbol{I}$	jednakowa wariancja i brak korelacji błędów
WLS-var	$\mathrm{diag}(\hat{\sigma}_1^2, \ldots, \hat{\sigma}_n^2)$	różne wariancje, brak korelacji

Metoda	Przyjęta macierz $\boldsymbol{W}_h$	Założenie
WLS-struct	$\mathrm{diag}(\boldsymbol{S}\mathbf{1}_m)$	wagi zależne od liczby szeregów składowych
MinT-cov	$\widehat{\boldsymbol{W}}_h$	pełna estymowana kowariancja błędów
MinT-shrink	$\widehat{\boldsymbol{W}}_{shrink}$	kowariancja stabilizowana shrinkage

OLS traktuje wszystkie prognozy bazowe jednakowo. Jest prostym punktem odniesienia, ale nie wykorzystuje różnic w zmienności błędów.

WLS uwzględnia różną wiarygodność prognoz przez wagi. W wariancie wariancyjnym większa wariancja błędu oznacza mniejszą wagę. Wariant strukturalny wykorzystuje liczbę szeregów składowych i nie wymaga reszt, ale opiera się na uproszczonych założeniach.

MinT (*Minimum Trace*) dobiera uzgodnienie tak, aby minimalizować sumę wariancji błędów prognoz uzgodnionych, czyli ślad ich macierzy kowariancji. Przy założeniu nieobciążoności prognoz bazowych rozwiązanie ma postać

$$\boldsymbol{G}_{MinT} = (\boldsymbol{S}^\top \boldsymbol{W}_h^{-1} \boldsymbol{S})^{-1} \boldsymbol{S}^\top \boldsymbol{W}_h^{-1}.$$

W praktyce $\boldsymbol{W}_h$ nie jest znana i szacuje się ją na podstawie zsynchronizowanych reszt prognoz bazowych. Klasyczny estymator z próby to

$$\widehat{\boldsymbol{W}} = \frac{1}{N-1} \sum_{t=1}^{N} (\boldsymbol{e}_t - \bar{\boldsymbol{e}})(\boldsymbol{e}_t - \bar{\boldsymbol{e}})^\top.$$

Przy dużej liczbie szeregów względem liczby obserwacji macierz ta może być niestabilna lub osobliwa. Shrinkage stabilizuje estymację przez przybliżenie macierzy pełnej do diagonalnej:

$$\widehat{\boldsymbol{W}}_{shrink} = (1-\lambda)\widehat{\boldsymbol{W}}_{sam} + \lambda\, \mathrm{diag}(\widehat{\boldsymbol{W}}_{sam}), \qquad 0 \le \lambda \le 1.$$

MinT wykorzystuje potencjalnie najwięcej informacji, bo uwzględnia zarówno wariancje, jak i kowariancje błędów. Jednocześnie wymaga odpowiedniej liczby reszt i stabilnego estymatora. Dlatego w projekcie warto porównać MinT-shrink z OLS i WLS, zamiast zakładać z góry, że najbardziej złożona metoda będzie najlepsza. Wzory macierzowe zakładają odwracalność odpowiednich macierzy; w praktyce konieczna może być regularizacja lub obliczenia numeryczne odporne na osobliwość.

4.6 Implementacja w R: `fable` i `hts`

W ekosystemie `fable` dane są zwykle przechowywane jako `tsibble`. Funkcja `aggregate_key()` definiuje strukturę agregacji, `model()` dopasowuje modele, a `reconcile()` dodaje metody uzgadniania. Poniżej schemat dla hierarchii region-sklep (nazwy kolumn należy dopasować do własnych danych):

```
library(dplyr)
library(tsibble)
library(fable)
library(fabletools)
```

```r
dane_h <- dane |>
  aggregate_key(region / sklep, wartosc = sum(wartosc))

modele <- dane_h |>
  model(
    ets = ETS(wartosc),
    arima = ARIMA(wartosc),
    snaive = SNAIVE(wartosc)
  )

modele_uzgodnione <- modele |>
  reconcile(
    bu = bottom_up(ets),
    td = top_down(ets, method = "average_proportions"),
    mo = middle_out(ets, split = 1), # split dopasować do hierarchii
    ols = min_trace(ets, method = "ols"),
    wls = min_trace(ets, method = "wls_var"),
    mint = min_trace(ets, method = "mint_shrink")
  )

prognozy <- modele_uzgodnione |> forecast(h = 12)
```

W pakiecie `hts` stosuje się obiekty klasy `hts` lub `gts`. Argument `method` wybiera sposób uzgadniania, a `fmethod` - model prognoz bazowych. Przykładowo `method = "comb"` wraz z `weights = "mint"` uruchamia optymalną kombinację z MinT.

```r
library(hts)

# bottom_matrix: kolumny zawierają szeregi najniższego poziomu.
y_hts <- hts::hts(bottom_matrix, nodes = list(2, c(3, 2)))

fc_bu <- forecast(y_hts, h = 12, method = "bu", fmethod = "ets")
fc_ols <- forecast(y_hts, h = 12, method = "comb",
                   weights = "ols", fmethod = "ets")
fc_mint <- forecast(y_hts, h = 12, method = "comb",
                    weights = "mint", covariance = "shr",
                    fmethod = "ets")
```

`fable` dobrze współpracuje z `tsibble` i potokami `dplyr`; `hts` jest przydatny w klasycznym podejściu opartym na obiektach `ts` i macierzach. W obu przypadkach należy sprawdzić kolejność węzłów, częstotliwość danych, poprawność agregatów i zgodność horyzontów.

5 Miary dokładności prognoz

Niech y_{T+h} będzie wartością rzeczywistą, a $\hat{y}_{T+h|T}$ prognozą. Błąd prognozy to

$$e_{T+h} = y_{T+h} - \hat{y}_{T+h|T}.$$

Miary należy obliczać dla tych samych okresów testowych i horyzontów. W hierarchii warto

najpierw raportować wyniki per szereg i per poziom, a dopiero potem wyznaczać jedną miarę zbiorczą. Surowych MAE i RMSE nie należy bezpośrednio porównywać między szeregami o różnych skalach.

5.1 MAE - Mean Absolute Error

$$MAE = \frac{1}{H} \sum_{h=1}^{H} |e_{T+h}|.$$

MAE jest średnią wartością bezwzględną błędu i ma jednostkę oryginalnej zmiennej. Łatwo je interpretować i jest mniej wrażliwe na pojedyncze duże pomyłki niż RMSE. Nie jest jednak bezpośrednio porównywalne między szeregami o bardzo różnych skalach. Minimalizacja oczekiwanej straty bezwzględnej jest powiązana z prognozą mediany warunkowej.

5.2 MAPE - Mean Absolute Percentage Error

$$MAPE = \frac{100\%}{H} \sum_{h=1}^{H} \left| \frac{y_{T+h} - \hat{y}_{T+h|T}}{y_{T+h}} \right|.$$

MAPE pokazuje średni błąd w procentach i ułatwia interpretację względną. Jest niezdefiniowane dla $y_{T+h} = 0$ i niestabilne dla wartości bliskich zeru. Nie powinno być główną miarą dla danych z częstymi zerami lub sporadycznym popytem.

5.3 MASE - Mean Absolute Scaled Error

MASE skaluje błąd testowy przez średni błąd prognozy naiwnej obliczony na zbiorze treningowym. Dla szeregu bez sezonowości:

$$MASE = \frac{\frac{1}{H} \sum_{h=1}^{H} |y_{T+h} - \hat{y}_{T+h|T}|}{\frac{1}{T-1} \sum_{t=2}^{T} |y_t - y_{t-1}|}.$$

Dla sezonu o długości m mianownik opiera się na różnicach sezonowych:

$$MASE_{sez} = \frac{\frac{1}{H} \sum_{h=1}^{H} |y_{T+h} - \hat{y}_{T+h|T}|}{\frac{1}{T-m} \sum_{t=m+1}^{T} |y_t - y_{t-m}|}.$$

Wartość mniejsza od 1 oznacza, że błąd testowy jest mniejszy niż referencyjna skala błędu naiwnego wyznaczona na treningu. MASE jest bezwymiarowe i nadaje się do porównywania szeregów o różnych skalach. Jest niezdefiniowane, gdy mianownik wynosi zero. W każdym podziale walidacyjnym mianownik trzeba wyznaczać wyłącznie z części treningowej.

5.4 RMSE - Root Mean Squared Error

$$RMSE = \sqrt{\frac{1}{H} \sum_{h=1}^{H} e_{T+h}^2}.$$

RMSE silniej karze duże pomyłki niż MAE, ponieważ błąd jest podnoszony do kwadratu. Jest wyrażone w jednostkach szeregu i może być zdominowane przez pojedyncze duże odchylenia. W projekcie warto raportować je razem z MAE, aby ocenić zarówno typową wielkość błędu, jak i wpływ dużych pomyłek. Minimalizacja straty kwadratowej jest powiązana z prognozą warunkowej średniej.

5.5 RMSSE - Root Mean Squared Scaled Error

RMSSE jest skalowaną wersją RMSE. Dla szeregu bez sezonowości:

$$RMSSE_i = \sqrt{\frac{\frac{1}{H}\sum_{h=1}^{H}(y_{i,T+h} - \hat{y}_{i,T+h|T})^2}{\frac{1}{T-1}\sum_{t=2}^{T}(y_{i,t} - y_{i,t-1})^2}}.$$

Dla danych sezonowych mianownik można oprzeć na sezonowych różnicach $y_{i,t} - y_{i,t-m}$. RMSSE jest bezwymiarowe, pozwala porównywać szeregi o różnych skalach i mocniej karze duże błędy niż MASE. Podobnie jak MASE wymaga niezerowego mianownika. W konkursie M5 mianownik liczono dla aktywnego okresu sprzedaży danego produktu, co ma znaczenie przy szeregach z późnym początkiem sprzedaży.

5.6 WRMSSE - Weighted RMSSE

WRMSSE agreguje wyniki RMSSE za pomocą wag odzwierciedlających znaczenie poszczególnych szeregów:

$$WRMSSE = \sum_{i=1}^{n} w_i RMSSE_i, \qquad w_i \geq 0, \qquad \sum_{i=1}^{n} w_i = 1.$$

Wagi mogą wynikać z przychodu, wolumenu, kosztu błędnej decyzji lub innego kryterium biznesowego. W konkursie M5 wagi wiązano ze skumulowaną wartością sprzedaży w ostatnich 28 dniach treningu. Własny projekt nie musi kopiować tego rozwiązania: sposób wyznaczenia wag powinien odpowiadać celowi analizy oraz być opisany w raporcie. W hierarchii trzeba też jasno wskazać, które węzły wchodzą do agregacji wyniku, ponieważ uwzględnianie równocześnie agregatów i ich składników może wielokrotnie ważyć te same obserwacje.

WRMSSE jest przydatne, gdy szeregi mają różną ważność praktyczną, np. w sprzedaży. Nie zastępuje jednak wyników per poziom: jedna liczba zbiorcza może ukrywać słabszą jakość prognoz dla małych, lecz istotnych operacyjnie szeregów. Należy zatem raportować WRMSSE razem z RMSSE lub innymi miarami w podziale na poziomy.

5.7 Zestawienie miar i przykładowe obliczenia w R

Miara	Skala	Główna zaleta	Ograniczenie
MAE	jednostka zmiennej	łatwa interpretacja	zależy od skali
MAPE	procent	intuicyjny wynik procentowy	problem zer i wartości bliskich zeru
MASE	bezwymiarowa	porównanie między skalami	mianownik może być zerowy
RMSE	jednostka zmiennej	silna kara za duże błędy	wrażliwość na obserwacje odstające
RMSSE	bezwymiarowa	skalowana kara za duże błędy	mianownik może być zerowy
WRMSSE	bezwymiarowa	wagi zgodne ze znaczeniem szeregów	wynik zależy od przyjętych wag

Poniższy kod pokazuje podstawowe obliczenia dla jednego szeregu. W praktyce należy uwzględnić braki danych, długość sezonu, aktywny okres szeregu oraz liczyć skale wyłącznie z treningu.

```r
# actual i pred: wektory wartości testowych i prognoz.
errors <- actual - pred
mae  <- mean(abs(errors), na.rm = TRUE)
rmse <- sqrt(mean(errors^2, na.rm = TRUE))

# MAPE wyłącznie dla niezerowych wartości rzeczywistych.
ok <- !is.na(actual) & !is.na(pred) & actual != 0
mape <- mean(abs(errors[ok] / actual[ok])) * 100

# Dla sezonowości m: mianownik obliczony na szeregu treningowym.
scale_mae  <- mean(abs(train[(m + 1):length(train)] -
                       train[1:(length(train) - m)]), na.rm = TRUE)
scale_rmse <- sqrt(mean((train[(m + 1):length(train)] -
                         train[1:(length(train) - m)])^2, na.rm = TRUE))

mase  <- mae / scale_mae
rmsse <- rmse / scale_rmse

# Dla wielu szeregów: wagi muszą być nieujemne i sumować się do 1.
# wrmsse <- sum(weights * rmsse_by_series)
```

6 Ocena wyników w hierarchii

6.1 Porównywanie poziomów i kontrola spójności

Wartości agregatów są zwykle większe niż wartości szeregów dolnego poziomu, dlatego MAE i RMSE należy przedstawiać osobno dla każdego poziomu. Można dodatkowo podać średnią nieważoną po szeregach (*macro-average*) albo średnią ważoną, np.

$$M_{weighted} = \sum_{i=1}^{n} w_i M_i, \qquad \sum_{i=1}^{n} w_i = 1,$$

gdzie M_i oznacza wybraną miarę dla szeregu i. Wagi powinny być określone przed analizą wyników i uzasadnione merytorycznie.

Spójność uzgodnionych prognoz można kontrolować za pomocą macierzy ograniczeń $\boldsymbol{C}$, dla której $\boldsymbol{C}\boldsymbol{y} = \boldsymbol{0}$. Przykładowa diagnostyka to

$$D_{coh} = \|\boldsymbol{C}\tilde{\boldsymbol{y}}\|_2.$$

Dla prognoz spójnych wartość powinna być równa zeru z dokładnością do błędów numerycznych. Wartość ta nie mierzy jednak błędu prognozy względem obserwacji rzeczywistej.

6.2 Walidacja krocząca i unikanie wycieku danych

Dane należy dzielić chronologicznie. Dla punktu odcięcia T model estymuje się na obserwacjach dostępnych do T, a następnie prognozuje kolejne H okresów. W walidacji kroczącej procedurę powtarza się dla kolejnych punktów odcięcia $T_1, \ldots, T_R$ i agreguje błędy, np.

$$MAE_{CV} = \frac{1}{RH} \sum_{r=1}^{R} \sum_{h=1}^{H} |y_{T_r+h} - \hat{y}_{T_r+h|T_r}|.$$

W każdym oknie wyłącznie dane treningowe mogą służyć do estymacji parametrów ETS/ARIMA, udziałów Top-Down i macierzy kowariancji MinT. Wykorzystanie informacji z okresu testowego prowadzi do wycieku danych i zawyża ocenę jakości.

7 Najważniejsze ograniczenia

- **Spójność nie oznacza dokładności.** Uzgadnianie gwarantuje relacje agregacyjne, ale nie gwarantuje poprawy każdej miary w każdym węźle.
- **MinT zależy od estymacji kowariancji.** Przy dużej hierarchii i krótkiej historii shrinkage może być stabilniejszy niż pełna macierz z próby.
- **Top-Down wymaga sensownych udziałów.** Udziały historyczne mogą być niestabilne, gdy zmienia się struktura danych lub mianownik jest bliski zeru.
- **Prognozy liniowe mogą być ujemne.** Jeśli zmienna musi być nieujemna, należy rozważyć metody z ograniczeniami; nie są one tym samym co zwykła projekcja liniowa.
- **Wzory zakładają sumowanie.** Dla średnich, udziałów i wskaźników należy zdefiniować inne ograniczenia agregacyjne.
- **Porównanie musi być uczciwe.** Wszystkie metody powinny korzystać z tych samych okresów testowych, horyzontów i zbiorów szeregów.